

DataMedical Cost Personal Datasets

Cristian Trofusha, Samuele Epiceno, Giuseppe Antonio Arcuri, Miriam Formaro

29 agosto 2026

Indice

1	Introduzione	2
1.1	Descrizione del dataset	2
1.2	Obiettivi dell'analisi	2
1.3	Risultati attesi	2
2	Descrizione del dataset e Analisi Preliminare	2
2.1	Statistiche descrittive	2
2.2	Codifica delle variabili categoriche	3
2.3	Distribuzione della variabile target	3
2.4	Matrice di correlazione	4
2.5	Matrice di dispersione	4
3	Modelli Inferenziali, Forme Funzionali e Multicollinearità	5
3.1	Il modello di regressione lineare multipla	5
3.2	Modello completo	5
3.3	Confronto dei possibili modelli	6
3.4	Selezione del modello: Best Subset Selection	7
3.5	Analisi del modello finale	7
3.6	Multicollinearità	8
4	Eteroschedasticità e Analisi dei Residui	8
4.1	Analisi grafica	8
4.2	Test di Breusch-Pagan e White	9
4.3	Rimedio 1: inclusione del termine di interazione $\text{smoker} \times \text{bmi}$	10
4.4	Rimedio 2: Modello Lineare Robusto (RLM)	12
4.5	Sintesi	12
5	Modelli Predittivi: Regolarizzazione	13
5.1	Impostazione	13
5.2	Trace plot dei coefficienti	13
5.3	Cross-Validation: MSE vs. $-\log(\lambda)$	14
5.4	Confronto dei modelli	15
6	Conclusioni	16

1 Introduzione

1.1 Descrizione del dataset

Il dataset *Medical Cost Personal Datasets* raccoglie $n = 1338$ osservazioni relative a beneficiari di polizze assicurative sanitarie negli Stati Uniti. Per ciascun individuo sono disponibili 7 variabili:

- **charges** (variabile target, continua): spesa medica annua addebitata dall'assicurazione, in USD;
- **age** (continua): età dell'assicurato, da 18 a 64 anni;
- **sex** (categorica): **male** / **female**;
- **bmi** (continua): indice di massa corporea (kg/m^2);
- **children** (discreta): numero di figli a carico coperti dalla polizza, da 0 a 5;
- **smoker** (categorica): **yes** / **no**;
- **region** (categorica): area residenziale USA (**northeast**, **northwest**, **southeast**, **southwest**).

Dopo la rimozione di un'osservazione duplicata (identica su tutte le variabili), il dataset di lavoro consta di $n = 1337$ osservazioni, senza valori mancanti.

1.2 Obiettivi dell'analisi

L'analisi persegue tre obiettivi complementari:

1. **Descrittivo**: visualizzare la distribuzione di **charges** e le relazioni con i regressori disponibili;
2. **Inferenziale**: stimare un modello di regressione lineare che identifichi i regressori statisticamente significativi della spesa sanitaria, valutandone la forma funzionale ottimale, la significatività congiunta e individuale dei regressori, e gestire l'eventuale presenza di multicollinearità ed eteroschedasticità;
3. **Predittivo**: confrontare tecniche di regolarizzazione (Ridge, LASSO, Elastic Net) con l'OLS classico in termini di errore di previsione fuori campione, valutandone la capacità di selezione automatica delle variabili.

1.3 Risultati attesi

Sulla base della letteratura relativa a questo dataset e dell'evidenza grafica preliminare, ci si attende che lo stato di fumatore (**smoker**) sia il principale determinante della spesa, seguito da età e BMI, con un effetto marginale del numero di figli; le variabili **sex** e **region** sono attese come non (o debolmente) significative.

2 Descrizione del dataset e Analisi Preliminare

2.1 Statistiche descrittive

La Tabella 1 riporta le statistiche descrittive delle variabili numeriche.

Tabella 1: Statistiche descrittive delle variabili numeriche ($n = 1337$)

Variabile	Media	Std	Min	Q1	Mediana	Max
age	39.22	14.04	18.00	27.00	39.00	64.00
bmi	30.66	6.10	15.96	26.29	30.40	53.13
children	1.10	1.21	0.00	0.00	1.00	5.00
charges	13 279.12	12 110.36	1 121.87	4 746.34	9 386.16	63 770.43

Le variabili categoriche mostrano le seguenti frequenze: **sex** sostanzialmente bilanciato (50.5% *male*, 49.5% *female*); **smoker** fortemente sbilanciato (79.5% *no*, 20.5% *yes*, coerente con la prevalenza reale del fumo); **region** pressoché equidistribuita (southeast 27.2%, le altre tre $\approx 24\%$ ciascuna).

2.2 Codifica delle variabili categoriche

Le variabili categoriche sono state trasformate in variabili dummy (0/1) mediante *one-hot encoding*, escludendo la prima categoria in ordine alfabetico per ciascuna variabile al fine di evitare la trappola delle *dummy*, ossia la collinearità perfetta che si avrebbe includendo tutte le categorie insieme all'intercetta: Le categorie di riferimento (corrispondenti a coefficiente nullo per costruzione) sono: **sex=female**, **smoker=no**, **region=northeast**. Si ottengono così 8 regressori: **age**, **bmi**, **children**, **sex_male**, **smoker_yes**, **region_northwest**, **region_southeast**, **region_southwest**.

2.3 Distribuzione della variabile target

La Figura 1 mostra istogramma e densità di **charges** in livelli e in logaritmo. La distribuzione in livelli è fortemente asimmetrica: skewness = 1.52, curtosi= 1.60, con media (\$13 279) nettamente superiore alla mediana (\$9 386). La forma è inoltre chiaramente **bimodale**, con un secondo addensamento intorno a valori compresi tra \$35 000 e \$45 000. La trasformazione logaritmica riduce l'asimmetria ma non elimina del tutto la bimodalità residua.




Figura 1: Istogramma e densità di **charges** (sinistra) e di $\log(\text{charges})$ (destra).

La Figura 2 chiarisce l'origine della bimodalità: lo stato di fumatore separa nettamente due sotto-popolazioni con spesa media molto diversa (mediana $\approx \$34\,500$ per i fumatori contro $\approx \$7\,300$ per i non fumatori), e all'interno di ciascun gruppo la spesa cresce con età e BMI.




Figura 2: **charges** per stato di fumatore e relazione con **age**/**bmi** colorata per **smoker**.

2.4 Matrice di correlazione

La Figura 3 riporta la matrice di correlazione di Pearson tra tutte le variabili (dopo l'encoding). La correlazione con **charges** più forte è quella con **smoker_yes** ($\rho = 0.787$), seguita da **age** ($\rho = 0.298$) e **bmi** ($\rho = 0.198$); le altre variabili mostrano correlazioni deboli ($|\rho| < 0.08$). Le correlazioni tra i regressori sono contenute (il valore assoluto massimo, 0.35, si osserva tra le dummy di regione per costruzione), suggerendo a l'assenza di multicollinearità, ipotesi verificata nella Sezione 3.6.




Figura 3: Matrice di correlazione.

2.5 Matrice di dispersione

La Figura 4 mostra la scatterplot matrix delle variabili numeriche con rette di regressione costruite tramite OLS. La relazione tra **age** e **charges** appare quasi lineare "a strati" (dovuta ai sottogruppi **smoker**); quella tra **bmi** e **charges** è positiva ma più rumorosa; quella tra **children** e **charges** è pressoché piatta.




Figura 4: Scatterplot matrix delle variabili numeriche con rette di regressione.

3 Modelli Inferenziali, Forme Funzionali e Multicollinearità

3.1 Il modello di regressione lineare multipla

Il modello di partenza (forma lin-lin, tutte le variabili in livelli) è:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{sex_male}_i + \beta_5 \text{smoker_yes}_i + \sum_r \gamma_r \text{region}_{r,i} + u_i \quad (1)$$

stimato con il metodo dei minimi quadrati ordinari, sotto le ipotesi di Gauss-Markov ($\mathbb{E}[u_i|X_i] = 0$, $\text{Var}(u_i|X_i) = \sigma^2$, $\text{Cov}(u_i, u_j|X) = 0$ per $i \neq j$).

3.2 Modello completo

La Tabella 2 riporta l'output del modello (1) con tutti gli 8 regressori.

Tabella 2: Modello OLS completo (lin-lin): $R^2 = 0.751$, $R_{adj}^2 = 0.749$, $F(8, 1328) = 500.0$ ($p \approx 0$)

Regressore	Coeff.	Std. Err.	t	p -value	Sign.
costante	-11 940.0	988.23	-12.08	< 0.001	***
age	256.76	11.91	21.56	< 0.001	***
bmi	339.25	28.61	11.86	< 0.001	***
children	474.82	137.90	3.44	0.001	***
sex_male	-129.48	333.20	-0.39	0.698	n.s.
smoker_yes	23 850.0	413.35	57.69	< 0.001	***
region_northwest	-349.23	476.82	-0.73	0.464	n.s.
region_southeast	-1 035.27	478.87	-2.16	0.031	*
region_southwest	-960.08	478.11	-2.01	0.045	*

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; n.s. non significativo

I residui del modello completo mostrano forte non-normalità (skewness = 1.21, curtosi = 5.65), un primo segnale d'allarme che verrà approfondito nella Sezione 4.

3.3 Confronto dei possibili modelli

Sono state confrontati quattro modelli: lin-lin, log-log, log-lin e lin-log:

$$\text{lin-lin: } y = \beta_0 + \beta' \mathbf{x} + u \quad (2)$$

$$\text{log-log: } \ln(y) = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (3)$$

$$\text{log-lin: } \ln(y) = \beta_0 + \beta' \mathbf{x} + u \quad (4)$$

$$\text{lin-log: } y = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (5)$$

dove $\mathbf{z}$ raccoglie **children** e le dummy (che restano sempre in livelli, poiché il logaritmo non è definito per **children**=0 e privo di senso per variabili binarie).

Tabella 3: Confronto dei modelli

Forma	Y	R^2	R_{adj}^2	AIC	Skew resid.	Kurt resid.
lin-lin	charges	0.751	0.749	27 094.2	1.21	5.65
log-log	$\ln(\text{charges})$	0.769	0.767	1 627.4	1.85	7.67
log-lin	$\ln(\text{charges})$	0.768	0.766	1 633.2	1.68	7.32
lin-log	charges	0.744	0.743	27 127.8	1.18	5.45

I valori di R^2 e AIC riportati in Tabella 3 **non sono direttamente confrontabili tra le righe con variabile dipendente diversa** (**charges** in livelli contro $\ln(\text{charges})$): la varianza totale da spiegare, su cui si basano sia R^2 sia la log-verosimiglianza (e quindi l'AIC), è calcolata su due scale numeriche differenti. Il confronto è quindi valido solo *entro* lo stesso gruppo (lin-lin vs. lin-log; log-log vs. log-lin), non tra i due gruppi.

La scelta della forma funzionale finale non si basa dunque su un confronto diretto di questi indici: **charges** è una variabile strettamente positiva (supporto $(0, +\infty)$), trattandosi di una spesa monetaria. Il modello lin-lin, essendo lineare e non vincolato, può generare previsioni negative, prive di senso economico: stimato ai valori minimi osservati nel campione (**age**=18, **bmi**=15.96, **children**=0, **smoker_yes**=0), il modello lin-lin a 4 regressori (Sezione 3.5) produce una previsione di $-\$2321.86$, un valore impossibile per una spesa sanitaria.

La trasformazione logaritmica risolve strutturalmente il problema: $\ln(\text{charges})$ ha supporto $(-\infty, +\infty)$, coerente con l'ipotesi classica dell'errore gaussiano non vincolato ($u_i \sim N(0, \sigma^2)$), e

garantisce che le previsioni ritrasformate $\exp(\ln(\widehat{\text{charges}}))$ siano sempre positive per costruzione. Per questo motivo la forma **log-lin** viene adottata come specificazione finale nel prosieguo dell'analisi.

3.4 Selezione del modello: Best Subset Selection

La scelta del modello finale è stata effettuata tramite **Best Subset Selection**: una ricerca esaustiva su tutte le $2^8 - 1 = 255$ combinazioni non vuote di regressori (praticabile grazie al basso numero di regressori disponibili), applicata alla forma log-lin motivata in Sezione 3.3, selezionando il sottoinsieme che minimizza il criterio BIC che penalizza la complessità più severamente dell'AIC ed è quindi preferibile quando l'obiettivo è un modello parsimonioso. Applicata direttamente a $\ln(\text{charges})$ su tutti gli 8 regressori, la procedura individua come ottimo un modello a 7 regressori (`age`, `bmi`, `children`, `sex_male`, `smoker_yes`, `region_southeast`, `region_southwest`; BIC= 1 676.0), poiché in scala logaritmica `sex_male` e due dummy di regione risultano deboli ma statisticamente significative, a differenza di quanto osservato in scala lin-lin. Per preservare la parsimonia e la comparabilità con l'estensione con interazione (Sezione 4), si mantiene tuttavia la specificazione a 4 regressori già individuata nello Step 2:

$$\ln(\text{charges}_i) = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{smoker_yes}_i + u_i \quad (6)$$

il cui BIC (1684.2) risulta solo marginalmente superiore a quello del modello a 7 regressori, a fronte di una specificazione più parsimoniosa e direttamente interpretabile.

3.5 Analisi del modello finale

La Tabella 4 riporta l'output completo del modello log-lin (6).

Tabella 4: Modello finale (log-lin, 4 regressori)

Regressore	Coeff.	Std. Err.	t	p -value	IC 95%
costante	6.9850	0.070	100.17	< 0.001	[6.848, 7.122]
age	0.0347	0.001	39.43	< 0.001	[0.033, 0.037]
bmi	0.0106	0.002	5.24	< 0.001	[0.007, 0.015]
children	0.1009	0.010	9.89	< 0.001	[0.081, 0.121]
smoker_yes	1.5427	0.030	50.69	< 0.001	[1.483, 1.602]

Bontà di adattamento: $R^2 = 0.762$, $R_{adj}^2 = 0.761$: il modello spiega il 76.2% della varianza di $\ln(\text{charges})$.

Test F globale: verifica la significatività congiunta di tutti i regressori ($H_0 : \beta_1 = \dots = \beta_k = 0$). Si ottiene $F(4, 1332) = 1065.2$, $p \approx 0$: si rigetta H_0 , il modello nel suo complesso è significativo.

Test t sui singoli coefficienti ($H_0 : \beta_j = 0$ vs. $H_1 : \beta_j \neq 0$, statistica $t = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$): tutti e 4 i regressori sono significativi. In forma log-lin i coefficienti si interpretano in termini di percentuali: $(\exp(\hat{\beta}_j) - 1) \times 100$ è la variazione percentuale attesa di `charges` per un incremento unitario di x_j , a parità delle altre covariate. Un anno di età in più è associato a una variazione attesa della spesa di +3.5%; un punto di BMI in più a +1.1%; un figlio in più a +10.6%; essere fumatori a +367.7% ($(\exp(1.5427) - 1) \times 100$), effetto di gran lunga dominante, coerente con la correlazione $\rho = 0.787$ osservata in Sez. 2.

3.6 Multicollinearità

Il **Variance Inflation Factor** per il regressore j è definito come

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (7)$$

dove R_j^2 è il coefficiente di determinazione della regressione di x_j su tutti gli altri regressori. La Tabella 5 riporta i VIF del modello finale.

Tabella 5: Variance Inflation Factor, modello finale

Regressore	VIF
age	1.014
bmi	1.012
children	1.002
smoker_yes	1.001

Tutti i VIF sono prossimi a 1 (soglia di allarme convenzionale: $\text{VIF} \geq 10$): nessuna multicollinearità rilevante tra i regressori.

Come indicatore complementare è stato calcolato il **Condition Number** k della matrice disegno X (inclusa la costante), definito semplicemente come la radice quadrata del rapporto tra l'autovalore massimo e l'autovalore minimo della matrice $X'X$:

$$k = \sqrt{\frac{\lambda_{\max}(X'X)}{\lambda_{\min}(X'X)}} \quad (8)$$

Si ottiene $k = 291.6$ (soglie di riferimento: $k < 10$ nessun problema, $10 \leq k < 30$ moderato, $k \geq 30$ severo). Il valore elevato è in larga parte attribuibile alla diversa scala di misura dei regressori (age e bmi assumono valori nell'ordine delle decine, mentre le dummy sono 0/1), piuttosto che a una reale relazione lineare tra le variabili: coerentemente, tutti i VIF restano prossimi a 1. Poiché il VIF non risente della scala delle variabili, viene qui considerato l'indicatore più affidabile per la diagnosi di multicollinearità. **Conclusione:** nessun problema di multicollinearità rilevante nel modello finale.

4 Eteroschedasticità e Analisi dei Residui

4.1 Analisi grafica

La Figura 5 mostra i residui del modello log-lin finale (6) (in scala logaritmica) contro i valori stimati, colorati per stato di fumatore. Anche in scala logaritmica si osservano due nubi nettamente separate, ciascuna con un andamento non lineare, sintomo di eteroschedasticità residua e di una possibile interazione **smoker**×**bmi** non ancora modellata.




Figura 5: Residui vs. Fitted values (colorati per **smoker**) e istogramma dei residui con densità normale teorica sovrapposta, modello log-lin finale.

Il Q-Q plot (Figura 6) conferma code pesanti e uno scostamento dalla normalità, sebbene meno marcato che in scala lineare.




Figura 6: Q-Q plot dei residui del modello log-lin finale.

4.2 Test di Breusch-Pagan e White

Il test di **Breusch-Pagan** verifica $H_0 : \text{Var}(u_i|X_i) = \sigma^2$ (omoschedasticità) contro H_1 : la varianza dipende linearmente dai regressori, tramite la regressione ausiliaria $\hat{u}_i^2 = \delta_0 + \delta_1 x_{1i} + \dots + \delta_k x_{ki} + v_i$ e la statistica $\text{LM} = nR_{aux}^2 \sim \chi_k^2$. Il test di **White** generalizza includendo nella regressione ausiliaria anche quadrati e prodotti incrociati dei regressori, risultando robusto a forme di eteroschedasticità non lineari.

Tabella 6: Test di eteroschedasticità sul modello log-lin finale

Test	Statistica	p -value	Statistica F	p -value (F)
Breusch-Pagan	LM= 81.23	9.56×10^{-17}	21.54	3.08×10^{-17}
White	LM= 140.86	1.41×10^{-23}	11.99	5.47×10^{-25}

Entrambi i test rigettano nettamente H_0 ($p < 0.001$): **eteroschedasticità confermata anche in scala logaritmica**. La trasformazione log, pur risolvendo il problema della non negatività delle previsioni (Sezione 3.3), non garantisce di per sé varianza costante dei residui.

4.3 Rimedio 1: inclusione del termine di interazione $\text{smoker} \times \text{bmi}$

L'analisi esplorativa (Sezione 2) e il pattern osservato nei residui (Sezione 4.1) suggeriscono che l'effetto di **bmi** su **charges** non sia lo stesso per fumatori e non fumatori. Si stima quindi un modello log-lin esteso che include il termine di interazione $\text{smoker_yes} \times \text{bmi}$:

$$\ln(\text{charges}_i) = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{smoker_yes}_i + \beta_5 (\text{smoker_yes}_i \times \text{bmi}_i) + u_i \quad (9)$$

Tabella 7: Modello log-lin con interazione $\text{smoker} \times \text{bmi}$

Regressore	Coeff.	Std. Err.	t	p -value
costante	7.2740	0.074	97.94	< 0.001
age	0.0350	0.001	40.94	< 0.001
bmi	0.0009	0.002	0.39	0.695
children	0.1020	0.010	10.32	< 0.001
smoker_yes	0.1859	0.148	1.26	0.209
smoker_yes $\times$ bmi	0.0442	0.005	9.37	< 0.001

Bontà di adattamento: $R^2 = 0.777$ e $R_{adj}^2 = 0.776$, contro $R^2 = 0.762$ e $R_{adj}^2 = 0.761$ del modello senza interazione. Il test F incrementale tra il modello conferma la significatività congiunta dell'aggiunta: $F(1, 1331) = 87.8$, $p \approx 3.03 \times 10^{-20}$, in linea con il test t sul singolo coefficiente ($t = 9.37$, $p < 0.001$). L'interazione è quindi altamente significativa.

Interpretazione: l'effetto marginale di **bmi** risulta diverso nei due gruppi. Per i non fumatori, $(\exp(\hat{\beta}_2) - 1) \times 100 = +0.09\%$ per punto di BMI, non significativo ($p = 0.695$); per i fumatori, sommando i coefficienti ($\hat{\beta}_2 + \hat{\beta}_5 = 0.0451$, $t = 10.81$, $p < 0.001$), $(\exp(0.0451) - 1) \times 100 = +4.61\%$ per punto di BMI, un effetto significativo. Questo spiega precisamente il pattern quasi discontinuo osservato nello Step 1 (Figura 2): l'obesità amplifica sensibilmente i costi sanitari specificamente nei fumatori, mentre per i non fumatori il BMI ha un effetto marginale quasi nullo sulla spesa a parità di età e figli.

Di conseguenza anche i coefficienti principali di **bmi** e **smoker_yes** cambiano interpretazione: rappresentano il valore stimato quando l'altra variabile coinvolta nell'interazione è pari a zero, non più un effetto medio costante. In particolare **smoker_yes** ora rappresenta l'effetto di essere fumatori quando **bmi**=0, un valore fuori dal range osservato (da 15.96 a 53.13) e privo di senso diretto (coerentemente non significativo, $p = 0.209$). L'effetto complessivo del fumo, calcolato al BMI medio del campione ($\overline{\text{bmi}} = 30.66$; $t = 52.27$, $p < 0.001$), è $(\exp(0.1859 + 0.0442 \times 30.66) - 1) \times 100 \approx +367\%$, coerente con la stima $+367.7\%$ del modello senza interazione.

Tabella 8: Variance Inflation Factor, modello con interazione

Regressore	VIF
age	1.015
bmi	1.297
children	1.002
smoker_yes	25.14
smoker_yes $\times$ bmi	25.44

Il VIF (indipendente dalla scala di **charges**, poiché dipende solo dalla matrice dei regressori X) evidenzia una collinearità elevata tra **smoker_yes** e il termine di interazione ($VIF \approx 25$), conseguenza meccanica dell'uso di **bmi** non centrata: nel sottogruppo dei fumatori, **smoker_yes** $\times$ **bmi** è quasi proporzionale a **bmi** stessa. Questo non compromette la validità del modello (i coefficienti restano stimati correttamente e il termine di interazione resta altamente significativo), ma riduce la precisione con cui si può scomporre l'effetto tra i due termini correlati; centrando **bmi** sulla propria media si ridurrebbe il VIF senza alterare fit, R^2 o significatività, a scapito della diretta interpretabilità dei coefficienti principali in corrispondenza di **bmi**=0.

Tabella 9: Confronto dei test di eteroschedasticità: senza vs. con interazione (log-lin)

Test	LM senza interazione	p -value	LM con interazione	p -value
Breusch-Pagan	81.23	9.56×10^{-17}	76.57	4.37×10^{-15}
White	140.86	1.41×10^{-23}	129.74	7.21×10^{-20}

A differenza di quanto accadrebbe in scala lin-lin, dove l'interazione elimina l'eteroschedasticità (i due test tornerebbero non significativi), in scala log-lin **entrambi i test restano altamente significativi** anche dopo l'inclusione dell'interazione: la statistica LM di Breusch-Pagan si riduce solo del 5.7% (da 81.23 a 76.57) e quella di White del 7.9% (da 140.86 a 129.74), entrambe ancora con $p < 0.001$. L'interazione migliora quindi in modo sostanziale il fit del modello, ma **non risolve** l'eteroschedasticità nella specificazione log-lin: la trasformazione logaritmica ha già assorbito gran parte della relazione media-varianza, lasciando un margine di correzione residuo minore rispetto alla specificazione in livelli.




Figura 7: Confronto Residui vs Fitted (scala logaritmica): modello senza interazione (sinistra) e con interazione **smoker_yes** $\times$ **bmi** (destra), colorati per **smoker**.

Il pannello destro mostra come, per i non fumatori, la nube dei residui si restringa e assuma un andamento più regolare per bassi valori stimati; per i fumatori la dispersione decrescente resta ben visibile, coerente con la persistenza dell'eteroschedasticità rilevata dai test.

Va inoltre notato che skewness e curtosi dei residui aumentano leggermente nel modello con interazione (skewness $1.60 \rightarrow 1.76$, curtosi $7.18 \rightarrow 7.80$).

4.4 Rimedio 2: Modello Lineare Robusto (RLM)

Il Modello Lineare Robusto (RLM) è stato applicato al modello log-lin finale (senza interazione), come ulteriore strumento diagnostico indipendente dalla specificazione adottata, per verificare quanto le osservazioni anomale (outlier) influenzino le stime OLS: a differenza dei minimi quadrati ordinari, l'RLM attribuisce un peso $w_i < 1$ alle osservazioni con residuo elevato, riducendone l'impatto sulla stima dei coefficienti.

Tabella 10: Confronto coefficienti (log-lin) e semi-elasticità: OLS vs. RLM

Regressore	OLS	Semi-elast. OLS	RLM	Semi-elast. RLM
costante	6.9850	–	6.9442	–
age	0.0347	+3.5%	0.0398	+4.1%
bmi	0.0106	+1.1%	0.0030	+0.3%
children	0.1009	+10.6%	0.1020	+10.7%
smoker_yes	1.5427	+367.7%	1.5709	+381.1%

L'RLM assegna un peso molto basso a un insieme di osservazioni anomale, in questo caso prevalentemente soggetti giovani e non fumatori con **charges** elevate rispetto al proprio profilo (verosimilmente per fattori di rischio non osservati nel dataset). Rispetto all'OLS, l'RLM stima un effetto di **bmi** più contenuto (semi-elasticità: $+1.1\% \rightarrow +0.3\%$ per punto) e un effetto di **age** e **smoker_yes** leggermente più marcato ($+3.5\% \rightarrow +4.1\%$ e $+367.7\% \rightarrow +381.1\%$): alcuni outlier attenuano nell'OLS classico l'effetto di età e fumo, effetto che l'RLM restituisce con maggiore fedeltà una volta ridotto il loro peso.




Figura 8: Distribuzione dei pesi assegnati dal Modello Lineare Robusto (modello log-lin finale).

4.5 Sintesi

Nella specificazione log-lin adottata come modello finale, l'eteroschedasticità rilevata in Sezione 4.2 (Breusch-Pagan e White, $p < 0.001$) persiste anche dopo l'inclusione del termine di interazione

smoker_yes×**bmi** (Rimedio 1): l'interazione migliora significativamente il fit (R^2 da 0.762 a 0.777) ma riduce le statistiche LM solo del tra il 5.7% e il 7.9%, che restano altamente significative. La trasformazione logaritmica, avendo già stabilizzato gran parte della relazione media-varianza, lascia dunque un margine di correzione residuo minore rispetto alla specificazione in livelli, dove lo stesso termine di interazione elimina l'eteroschedasticità. Il Modello Lineare Robusto (Rimedio 2) conferma che alcune osservazioni anomale distorcono le stime OLS, in particolare quella di **bmi**. Data la persistenza dell'eteroschedasticità, l'uso di errori standard robusti resta comunque utile per un'inferenza valida sui coefficienti del modello log-lin finale.

5 Modelli Predittivi: Regularizzazione

5.1 Impostazione

A differenza degli Step precedenti, in questa sezione si utilizzano **tutti gli 8 regressori** codificati, lasciando che siano le tecniche di regularizzazione a operare la selezione/riduzione delle variabili in modo automatico. Il campione è stato suddiviso in training (80%, $n = 1069$) e test set (20%, $n = 268$); i regressori continui (**age**, **bmi**, **children**) sono stati standardizzati ($z = (x - \bar{x})/s$, scaler stimato solo sul training set per evitare *data leakage*), mentre le dummy restano in scala 0/1.

Le tre famiglie di modelli risolvono:

$$\text{Ridge: } \hat{\beta}_{\text{Ridge}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k \beta_j^2 \right\} \quad (10)$$

$$\text{LASSO: } \hat{\beta}_{\text{LASSO}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k |\beta_j| \right\} \quad (11)$$

$$\text{Elastic Net: } \hat{\beta}_{\text{EN}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \left[\alpha \sum_{j=1}^k |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^k \beta_j^2 \right] \right\} \quad (12)$$

dove $\lambda \geq 0$ è il parametro di regularizzazione e $\alpha \in [0, 1]$ pesa il contributo relativo delle penalità L1/L2 (testati $\alpha = 0.1$, a prevalenza Ridge, e $\alpha = 0.9$, a prevalenza LASSO).

È stata definita una griglia logaritmica decrescente di 100 valori, $\lambda \in \{10^4, \dots, 10^{-4}\}$, e per ciascun valore è stata eseguita una **10-fold cross-validation** sul training set.

5.2 Trace plot dei coefficienti

La Figura 9 mostra i *trace plot*: per λ grande tutti i coefficienti sono schiacciati verso 0; al decrescere di λ (verso destra, asse $-\log_{10} \lambda$) "si accendono" in ordine di importanza, con **smoker_yes** dominante seguito da **age** e **bmi**. Nel pannello LASSO si osserva la differenza qualitativa attesa rispetto a Ridge/Elastic Net: le variabili deboli (**sex_male** e le dummy di **region**) restano **esattamente a zero** per un ampio intervallo di λ , mentre con la penalità L2 si avvicinano a zero senza mai annullarsi.




Figura 9: Trace plot dei coefficienti in funzione di $-\log_{10}(\lambda)$.

5.3 Cross-Validation: MSE vs. $-\log(\lambda)$

La Figura 10 mostra le curve di CV-MSE (media $\pm$ errore standard sui 10 fold) in funzione di $-\log_{10}(\lambda)$. Il parametro di regolarizzazione ottimale λ_{min} è individuato come il valore che minimizza il CV-MSE medio sui 10 fold, evidenziato nel grafico da una linea verticale: è questo l'unico criterio adottato per la scelta di λ .




Figura 10: 10-fold CV MSE in funzione di $-\log_{10}(\lambda)$, con λ_{min} evidenziato (linea rossa).

5.4 Confronto dei modelli

La Tabella 11 riassume λ_{min} , MSE di cross-validation, MSE e R^2 sul test set, e numero di regressori non nulli per ciascun modello, confrontati con la baseline OLS (senza regolarizzazione) sullo stesso split.

Tabella 11: Confronto dei modelli di regolarizzazione (test set, $n = 268$)

Modello	λ_{min}	Test MSE	Test RMSE	Test R^2	Regr. non nulli
Ridge	0.628	35.59×10^6	5 966	0.8063	8/8
LASSO	79.25	36.73×10^6	6 060	0.8001	4/8
Elastic Net ($\alpha = 0.1$)	0.0008	35.62×10^6	5 968	0.8062	8/8
Elastic Net ($\alpha = 0.9$)	0.0072	35.62×10^6	5 968	0.8062	8/8
OLS (no reg.)	0	35.48×10^6	5 956	0.8069	8/8




Figura 11: Confronto del Test RMSE tra i modelli.

Selezione delle variabili: LASSO azzerava esattamente `sex_male`, `region_northwest`, `region_southeast`, `region_southwest`: le *stesse identiche* variabili escluse dalla Best Subset Selection nello Step 2 (Sezione 3.4). Questa convergenza tra un criterio classico e uno di regolarizzazione automatica costituisce una forte conferma incrociata della robustezza del modello a 4 regressori.

Confronto degli MSE: l'OLS non regolarizzato ottiene il Test RMSE più basso, per un margine contenuto. Ciò è coerente con la diagnosi di multicollinearità della Sez. 3.6: la regolarizzazione offre il massimo vantaggio quando vi è overfitting da collinearità o alta dimensionalità (p grande rispetto a n); qui invece $n = 1069 \gg p = 8$ e i regressori sono quasi ortogonali ($VIF \approx 1$), per cui Ridge ed Elastic Net convergono a λ_{min} vicino a zero (confermato dal fatto che i λ_{min} di Elastic Net si assestano su valori $\ll 1$, non sul bordo della griglia). Il costo del LASSO (RMSE leggermente più alto) riflette il classico *trade-off* bias-varianza: la penalità L1 introduce una piccola distorsione sui coefficienti sopravvissuti (es. `bmi`: $1927 \rightarrow 1772$) in cambio di sparsità e interpretabilità, non di un guadagno predittivo in questo specifico dataset.

6 Conclusioni

L'analisi ha permesso di individuare i regressori che influiscono la spesa sanitaria nel dataset *Medical Cost Personal Datasets*:

1. **Analisi descrittiva:** `charges` presenta una distribuzione fortemente asimmetrica e bimodale, generata principalmente dalla variabile fumatore/non fumatore.
2. **Modello inferenziale:** il modello finale $\ln(\text{charges}) = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{smoker_yes}$, in forma **log-lin** (scelta poiché `charges` è strettamente positiva, mentre il modello lin-lin può generare previsioni negative, come mostrato in Sezione 3.3), selezionato tramite BIC, spiega il 76.2% della varianza di $\ln(\text{charges})$ ($R_{adj}^2 = 0.761$) con tutti i coefficienti altamente significativi e nessuna multicollinearità rilevante ($VIF \approx 1$, $k = 291.6$). In termini di semi-elasticità, essere fumatori è associato a un aumento atteso della spesa del +367.7%, dominando nettamente gli effetti di `age` (+3.5%/anno), `bmi` (+1.1%/punto) e `children` (+10.6%/figlio). Le variabili `sex` e `region` non risultano determinanti significativi della spesa nella specificazione a 4 regressori.
3. **Eteroschedasticità:** confermata formalmente anche nel modello log-lin (Breusch-Pagan e White, $p < 0.001$). L'inserimento del termine di interazione `smoker_yes × bmi` migliora significativamente il fit (R^2 da 0.762 a 0.777, $t = 9.37$ sul coefficiente di interazione, $p <$

0.001) ma riduce le statistiche LM di soli tra il 5.7% e il 7.9%, che restano altamente significative: a differenza della specificazione in livelli, in scala log-lin l'eteroschedasticità non viene risolta, poiché la trasformazione logaritmica ha già assorbito gran parte della relazione media-varianza. In termini di semi-elasticità, l'effetto di **bmi** è pressoché nullo per i non fumatori (+0.09%/punto, $p = 0.695$) e marcato per i fumatori (+4.61%/punto, $p < 0.001$), spiegando il pattern osservato nell'analisi esplorativa. Data la persistenza dell'eteroschedasticità, l'uso di errori standard robusti resta consigliabile.

4. **Modelli predittivi:** Ridge, LASSO ed Elastic Net non migliorano la capacità predittiva rispetto all'OLS (Test RMSE compreso tra $\approx \$5\,956$ e $\$6\,060$ in tutti i casi), coerentemente con l'assenza di collinearità e la bassa dimensionalità del problema ($n \gg p$). Il LASSO conferma però in modo del tutto indipendente, tramite selezione automatica via penalità L1, la stessa riduzione a 4 variabili individuata dalla Best Subset Selection: una validazione incrociata robusta della specificazione finale.