

DataMedical Cost Personal Datasets (`insurance.csv`)

Cristian Trofusha, Samuele Epiceno, Giuseppe Antonio Arcuri, Miriam Formaro

23 agosto 2026

Indice

1	Introduzione	2
1.1	Descrizione del dataset	2
1.2	Obiettivi dell'analisi	2
1.3	Risultati attesi	2
2	Descrizione del dataset e Analisi Preliminare	2
2.1	Statistiche descrittive	2
2.2	Codifica delle variabili categoriche	3
2.3	Distribuzione della variabile target	3
2.4	Matrice di correlazione	4
2.5	Matrice di dispersione	4
3	Modelli Inferenziali, Forme Funzionali e Multicollinearità	5
3.1	Il modello di regressione lineare multipla	5
3.2	Modello completo	5
3.3	Confronto dei possibili modelli	6
3.4	Selezione del modello: Best Subset Selection	6
3.5	Analisi del modello finale	7
3.6	Multicollinearità	7
4	Eteroschedasticità e Analisi dei Residui	8
4.1	Analisi grafica	8
4.2	Test di Breusch-Pagan e White	9
4.3	Rimedio 1: trasformazione logaritmica	9
4.4	Rimedio 2: inclusione del termine di interazione $\text{smoker} \times \text{bmi}$	10
4.5	Rimedio 3: Modello Lineare Robusto (RLM)	13
4.6	Sintesi	13
5	Modelli Predittivi: Regolarizzazione	14
5.1	Impostazione	14
5.2	Trace plot dei coefficienti	14
5.3	Cross-Validation: MSE vs. $-\log(\lambda)$	15
5.4	Confronto dei modelli	16
6	Conclusioni	17

1 Introduzione

1.1 Descrizione del dataset

Il dataset *Medical Cost Personal Datasets* raccoglie $n = 1338$ osservazioni relative a beneficiari di polizze assicurative sanitarie negli Stati Uniti. Per ciascun individuo sono disponibili 7 variabili:

- **charges** (variabile target, continua): spesa medica annua addebitata dall'assicurazione, in USD;
- **age** (continua): età dell'assicurato, da 18 a 64 anni;
- **sex** (categorica): **male** / **female**;
- **bmi** (continua): indice di massa corporea (kg/m^2);
- **children** (discreta): numero di figli a carico coperti dalla polizza, da 0 a 5;
- **smoker** (categorica): **yes** / **no**;
- **region** (categorica): area residenziale USA (**northeast**, **northwest**, **southeast**, **southwest**).

Dopo la rimozione di un'osservazione duplicata (identica su tutte le variabili), il dataset di lavoro consta di $n = 1337$ osservazioni, senza valori mancanti.

1.2 Obiettivi dell'analisi

L'analisi persegue tre obiettivi complementari:

1. **Descrittivo**: visualizzare la distribuzione di **charges** e le relazioni con i regressori disponibili;
2. **Inferenziale**: stimare un modello di regressione lineare che identifichi i regressori statisticamente significativi della spesa sanitaria, valutandone la forma funzionale ottimale, la significatività congiunta e individuale dei regressori, e gestire l'eventuale presenza di multicollinearità ed eteroschedasticità;
3. **Predittivo**: confrontare tecniche di regolarizzazione (Ridge, LASSO, Elastic Net) con l'OLS classico in termini di errore di previsione fuori campione, valutandone la capacità di selezione automatica delle variabili.

1.3 Risultati attesi

Sulla base della letteratura relativa a questo dataset e dell'evidenza grafica preliminare, ci si attende che lo stato di fumatore (**smoker**) sia il principale determinante della spesa, seguito da età e BMI, con un effetto marginale del numero di figli; le variabili **sex** e **region** sono attese come non (o debolmente) significative. Data la forte asimmetria di **charges**, si ipotizza inoltre la presenza di eteroschedasticità nei residui del modello in livelli.

2 Descrizione del dataset e Analisi Preliminare

2.1 Statistiche descrittive

La Tabella 1 riporta le statistiche descrittive delle variabili numeriche.

Tabella 1: Statistiche descrittive delle variabili numeriche ($n = 1337$)

Variabile	Media	Std	Min	Q1	Mediana	Max
age	39.22	14.04	18.00	27.00	39.00	64.00
bmi	30.66	6.10	15.96	26.29	30.40	53.13
children	1.10	1.21	0.00	0.00	1.00	5.00
charges	13 279.12	12 110.36	1 121.87	4 746.34	9 386.16	63 770.43

Le variabili categoriche mostrano le seguenti frequenze: **sex** sostanzialmente bilanciato (50.5% *male*, 49.5% *female*); **smoker** fortemente sbilanciato (79.5% *no*, 20.5% *yes*, coerente con la prevalenza reale del fumo); **region** pressoché equidistribuita (southeast 27.2%, le altre tre $\approx 24\%$ ciascuna).

2.2 Codifica delle variabili categoriche

Le variabili categoriche sono state trasformate in variabili dummy (0/1) mediante *one-hot encoding*, escludendo la prima categoria in ordine alfabetico per ciascuna variabile (**drop_first=True**) al fine di evitare la *dummy variable trap*, ossia la collinearità perfetta che si avrebbe includendo tutte le categorie insieme all'intercetta: Le categorie di riferimento (baseline, corrispondenti a coefficiente nullo per costruzione) sono: **sex=female**, **smoker=no**, **region=northeast**. Si ottengono così 8 regressori: **age**, **bmi**, **children**, **sex_male**, **smoker_yes**, **region_northwest**, **region_southeast**, **region_southwest**.

2.3 Distribuzione della variabile target

La Figura 1 mostra istogramma e densità di **charges** in livelli e in logaritmo. La distribuzione in livelli è fortemente asimmetrica: skewness = 1.52, curtosi = 1.60 (rispetto a 0 della normale), con media (\$13 279) nettamente superiore alla mediana (\$9 386). La forma è inoltre chiaramente **bimodale**, con un secondo addensamento intorno a valori compresi tra \$35 000 e \$45 000. La trasformazione logaritmica riduce l'asimmetria ma non elimina del tutto la bimodalità residua.




Figura 1: Istogramma e densità di **charges** (sinistra) e di **log(charges)** (destra).

La Figura 2 chiarisce l'origine della bimodalità: lo stato di fumatore separa nettamente due sotto-popolazioni con spesa media molto diversa (mediana $\approx \$34\,500$ per i fumatori contro $\approx \$7\,300$ per i non fumatori), e all'interno di ciascun gruppo la spesa cresce con età e BMI.




Figura 2: `charges` per stato di fumatore e relazione con `age`/`bmi` colorata per `smoker`.

2.4 Matrice di correlazione

La Figura 3 riporta la matrice di correlazione di Pearson tra tutte le variabili (dopo l'encoding). La correlazione con `charges` più forte è quella con `smoker_yes` ($\rho = 0.787$), seguita da `age` ($\rho = 0.298$) e `bmi` ($\rho = 0.198$); le altre variabili mostrano correlazioni deboli ($|\rho| < 0.08$). Le correlazioni tra i regressori sono contenute (il valore assoluto massimo, 0.35, si osserva tra le dummy di regione per costruzione), suggerendo a l'assenza di multicollinearità grave, ipotesi verificata formalmente nella Sezione 3.6.




Figura 3: Matrice di correlazione.

2.5 Matrice di dispersione

La Figura 4 mostra la scatterplot matrix delle variabili numeriche con rette di regressione costruite tramite OLS. La relazione tra `age` e `charges` appare quasi lineare "a strati" (dovuta ai sottogruppi `smoker`); quella tra `bmi` e `charges` è positiva ma più rumorosa; quella tra `children` e `charges` è pressoché piatta.




Figura 4: Scatterplot matrix delle variabili numeriche con rette di regressione.

3 Modelli Inferenziali, Forme Funzionali e Multicollinearità

3.1 Il modello di regressione lineare multipla

Il modello di partenza (forma lin-lin, tutte le variabili in livelli) è:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{sex_male}_i + \beta_5 \text{smoker_yes}_i + \sum_r \gamma_r \text{region}_{r,i} + u_i \quad (1)$$

stimato con il metodo dei minimi quadrati ordinari, sotto le ipotesi di Gauss-Markov ($\mathbb{E}[u_i|X_i] = 0$, $\text{Var}(u_i|X_i) = \sigma^2$, $\text{Cov}(u_i, u_j|X) = 0$ per $i \neq j$).

3.2 Modello completo

La Tabella 2 riporta l'output del modello (1) con tutti gli 8 regressori.

Tabella 2: Modello OLS completo (lin-lin): $R^2 = 0.751$, $R_{adj}^2 = 0.749$, $F(8, 1328) = 500.0$ ($p \approx 0$)

Regressore	Coeff.	Std. Err.	t	p -value	Sign.
costante	-11 940.0	988.23	-12.08	< 0.001	***
age	256.76	11.91	21.56	< 0.001	***
bmi	339.25	28.61	11.86	< 0.001	***
children	474.82	137.90	3.44	0.001	***
sex_male	-129.48	333.20	-0.39	0.698	n.s.
smoker_yes	23 850.0	413.35	57.69	< 0.001	***
region_northwest	-349.23	476.82	-0.73	0.464	n.s.
region_southeast	-1 035.27	478.87	-2.16	0.031	*
region_southwest	-960.08	478.11	-2.01	0.045	*

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; n.s. non significativo

I residui del modello completo mostrano forte non-normalità (skewness = 1.21, curtosi = 5.65), un primo segnale d'allarme che verrà approfondito nella Sezione 4.

3.3 Confronto dei possibili modelli

Sono state confrontate quattro modelli: lin-lin, log-log, log-lin e lin-log:

$$\text{lin-lin: } y = \beta_0 + \beta' \mathbf{x} + u \quad (2)$$

$$\text{log-log: } \ln(y) = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (3)$$

$$\text{log-lin: } \ln(y) = \beta_0 + \beta' \mathbf{x} + u \quad (4)$$

$$\text{lin-log: } y = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (5)$$

dove $\mathbf{z}$ raccoglie **children** e le dummy (che restano sempre in livelli, poiché il logaritmo non è definito per **children**=0 e privo di senso per variabili binarie).

Tabella 3: Confronto delle forme funzionali

Forma	Y	R^2	R_{adj}^2	AIC	Skew resid.	Kurt resid.
lin-lin	charges	0.751	0.749	27 094.2	1.21	5.65
log-log	ln(charges)	0.769	0.767	1 627.4	1.85	7.67
log-lin	ln(charges)	0.768	0.766	1 633.2	1.68	7.32
lin-log	charges	0.744	0.743	27 127.8	1.18	5.45

3.4 Selezione del modello: Best Subset Selection

La scelta del modello finale è stata effettuata tramite **Best Subset Selection**: una ricerca esaustiva su tutte le $2^8 - 1 = 255$ combinazioni non vuote di regressori (praticabile grazie al basso numero di regressori disponibili), selezionando il sottoinsieme che minimizza il criterio BIC

$$\text{BIC} = n \ln(\text{SSE}/n) + k \ln(n) \quad (6)$$

che penalizza la complessità più severamente dell'AIC ed è quindi preferibile quando l'obiettivo è un modello parsimonioso. La procedura individua come modello ottimale:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{smoker_yes}_i + u_i \quad (7)$$

(BIC= 27 118.7 contro BIC= 27 141.0 del modello completo; il modello a 6 regressori scelto dal criterio AIC/ R_{adj}^2 differisce di appena 0.0007 in R_{adj}^2 e viene scartato in favore della maggiore parsimonia).

3.5 Analisi del modello finale

La Tabella 4 riporta l'output completo del modello (7).

Tabella 4: Modello finale (lin-lin, 4 regressori)

Regressore	Coeff.	Std. Err.	t	p -value	IC 95%
costante	-12 098.82	942.63	-12.84	< 0.001	[-13 948, -10 250]
age	257.77	11.91	21.64	< 0.001	[234.4, 281.1]
bmi	321.87	27.39	11.75	< 0.001	[268.1, 375.6]
children	472.98	137.88	3.43	0.001	[202.5, 743.5]
smoker__yes	23 810.40	411.41	57.87	< 0.001	[23 003, 24 617]

Bontà di adattamento: $R^2 = 0.750$, $R_{adj}^2 = 0.749$: il modello spiega il 75% della varianza di **charges**, valore praticamente identico a quello del modello completo (0.751), a conferma che le variabili escluse non aggiungono potere esplicativo.

Test F globale:

$$F = \frac{(SSR_{ristretto} - SSR_{completo})/q}{SSR_{completo}/(n - k - 1)} \sim F_{q, n-k-1} \quad \text{sotto } H_0 : \beta_1 = \dots = \beta_k = 0 \quad (8)$$

$F(4, 1332) = 996.5$, $p \approx 0$: si rigetta H_0 , il modello nel suo complesso è significativo.

Test t sui singoli coefficienti ($H_0 : \beta_j = 0$ vs. $H_1 : \beta_j \neq 0$, statistica $t = \hat{\beta}_j / SE(\hat{\beta}_j)$): tutti e 4 i regressori sono significativi a livello 0.1%. Interpretazione economica: a parità delle altre covariate, un anno di età in più è associato a +\$258 di spesa attesa; un punto di BMI in più a +\$322; un figlio in più a +\$473; essere fumatori a +\$23 810, effetto di gran lunga dominante, coerente con la correlazione $\rho = 0.787$ osservata in Sez. 2.

3.6 Multicollinearità

Il **Variance Inflation Factor** per il regressore j è definito come

$$VIF_j = \frac{1}{1 - R_j^2} \quad (9)$$

dove R_j^2 è il coefficiente di determinazione della regressione di x_j su tutti gli altri regressori. La Tabella 5 riporta i VIF del modello finale.

Tabella 5: Variance Inflation Factor, modello finale

Regressore	VIF
age	1.014
bmi	1.012
children	1.002
smoker__yes	1.001

Tutti i VIF sono prossimi a 1 (soglia di allarme convenzionale: $VIF \geq 10$): nessuna multicollinearità rilevante tra i regressori.

Come indicatore complementare è stato calcolato il **Condition Number** k della matrice disegno X (inclusa la costante), definito semplicemente come la radice quadrata del rapporto tra l'autovalore massimo e l'autovalore minimo della matrice $X'X$:

$$k = \sqrt{\frac{\lambda_{max}(X'X)}{\lambda_{min}(X'X)}} \quad (10)$$

Si ottiene $k = 291.6$ (soglie di riferimento: $k < 10$ nessun problema, $10 \leq k < 30$ moderato, $k \geq 30$ severo). Il valore elevato è in larga parte attribuibile alla diversa scala di misura dei regressori (age e bmi assumono valori nell'ordine delle decine, mentre le dummy sono 0/1), piuttosto che a una reale relazione lineare tra le variabili: coerentemente, tutti i VIF restano prossimi a 1. Poiché il VIF non risente della scala delle variabili, viene qui considerato l'indicatore più affidabile per la diagnosi di multicollinearità. **Conclusione:** nessun problema di multicollinearità rilevante nel modello finale.

4 Eteroschedasticità e Analisi dei Residui

4.1 Analisi grafica

La Figura 5 mostra i residui del modello finale (7) contro i valori stimati, colorati per stato di fumatore. Si osservano due nubi nettamente separate, ciascuna con un pattern non lineare, sintomo di eteroschedasticità e di non linearità residua (verosimile interazione `smoker` $\times$ `bmi` non inclusa nel modello additivo). L'istogramma dei residui mostra una bimodalità residua rispetto alla densità normale sovrapposta.




Figura 5: Residui vs. Fitted values (colorati per `smoker`) e istogramma dei residui con densità normale teorica sovrapposta.

Il Q-Q plot (Figura 6) conferma code pesanti a destra e di discostamento dalla normalità.




Figura 6: Q-Q plot dei residui del modello finale.

4.2 Test di Breusch-Pagan e White

Il test di **Breusch-Pagan** verifica $H_0 : \text{Var}(u_i|X_i) = \sigma^2$ (omoschedasticità) contro H_1 : la varianza dipende linearmente dai regressori, tramite la regressione ausiliaria $\hat{u}_i^2 = \delta_0 + \delta_1 x_{1i} + \dots + \delta_k x_{ki} + v_i$ e la statistica $\text{LM} = nR_{aux}^2 \sim \chi_k^2$. Il test di **White** generalizza includendo nella regressione ausiliaria anche quadrati e prodotti incrociati dei regressori, risultando robusto a forme di eteroschedasticità non lineari.

Tabella 6: Test di eteroschedasticità sul modello finale (lin-lin)

Test	Statistica	p -value	Statistica F	p -value (F)
Breusch-Pagan	LM= 116.98	2.36×10^{-24}	31.93	1.95×10^{-25}
White	LM= 128.25	4.65×10^{-21}	10.80	3.39×10^{-22}

Entrambi i test rigettano nettamente H_0 ($p < 0.001$): **eteroschedasticità confermata**.

4.3 Rimedio 1: trasformazione logaritmica

Applicando $\ln(\text{charges})$ come variabile dipendente sugli stessi 4 regressori si ottiene $R^2 = 0.762$, $R_{adj}^2 = 0.761$ (Tabella 7).

Tabella 7: Modello log-lin: $\ln(\text{charges}) = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{smoker_yes} + u$

Regressore	Coeff.	Std. Err.	t	p -value
costante	6.9850	0.070	100.17	< 0.001
age	0.0347	0.001	39.43	< 0.001
bmi	0.0106	0.002	5.24	< 0.001
children	0.1009	0.010	9.89	< 0.001
smoker_yes	1.5427	0.030	50.69	< 0.001

I coefficienti si interpretano come semi-elasticità: $\exp(\hat{\beta}_j) - 1$ è la variazione percentuale attesa di **charges** per un incremento unitario di x_j . Ad esempio, essere fumatori è associato a $(\exp(1.5427) - 1) \times 100 \approx 368\%$ di spesa in più, a parità di età/BMI/figli.

Ripetendo i test sui residui di questo modello (Tabella 8):

Tabella 8: Test di eteroschedasticità sul modello log-lin

Test	Statistica	p -value	Statistica F	p -value (F)
Breusch-Pagan	LM= 81.23	9.56×10^{-17}	21.54	3.08×10^{-17}
White	LM= 140.86	1.41×10^{-23}	11.99	5.47×10^{-25}

L'eteroschedasticità **persiste** (anzi il test di White peggiora leggermente). Il grafico Residui vs Fitted in scala logaritmica (Figura 7, pannello destro) mostra un pattern a "V" ancora più marcato che nel lin-lin: la trasformazione logaritmica da sola non risolve il problema, poiché la causa non è (solo) una relazione moltiplicativa media-varianza ma una interazione strutturale **smoker** $\times$ **bmi**/age assente da entrambe le specificazioni.




Figura 7: Confronto Residui vs. Fitted: modello lin-lin (sinistra) contro log-lin (destra).

4.4 Rimedio 2: inclusione del termine di interazione **smoker** $\times$ **bmi**

L'analisi esplorativa (Sezione 2) e il pattern osservato nei residui (Sezione 4.1) suggeriscono che l'effetto di **bmi** su **charges** non sia lo stesso per fumatori e non fumatori. Si stima quindi un modello esteso che include il termine di interazione **smoker**_{yes} $\times$ **bmi**:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{smoker_yes}_i + \beta_5 (\text{smoker_yes}_i \times \text{bmi}_i) + u_i \quad (11)$$

Tabella 9: Modello con interazione **smoker** $\times$ **bmi**

Regressore	Coeff.	Std. Err.	t	p -value
costante	-2 725.78	831.78	-3.28	0.001
age	264.88	9.56	27.70	< 0.001
bmi	5.68	24.88	0.23	0.820
children	508.48	110.69	4.59	< 0.001
smoker_yes	-20 195.20	1655.11	-12.20	< 0.001
smoker_yes $\times$ bmi	1 433.78	52.84	27.13	< 0.001

Bontà di adattamento: $R^2 = 0.839$ e $R_{adj}^2 = 0.838$, contro $R^2 = 0.750$ e $R_{adj}^2 = 0.749$ del modello senza interazione: un incremento sostanziale. Il test F incrementale tra il modello ristretto (senza interazione) e quello esteso conferma la significatività congiunta dell'aggiunta: $F(1, 1331) = 736.2$, $p \approx 2.06 \times 10^{-129}$, in linea con il test t sul singolo coefficiente ($t = 27.13$, $p < 0.001$). L'interazione è quindi altamente significativa.

Interpretazione: l'effetto marginale di **bmi** risulta radicalmente diverso nei due gruppi. Per i non fumatori, $\partial \text{charges} / \partial \text{bmi} = \hat{\beta}_2 = \5.68 per punto di BMI, non significativo ($p = 0.820$); per i fumatori, $\partial \text{charges} / \partial \text{bmi} = \hat{\beta}_2 + \hat{\beta}_5 = \$5.68 + \$1\,433.78 = \$1\,439.45$ per punto di BMI, un effetto imponente e altamente significativo. Questo spiega precisamente il pattern quasi discontinuo osservato nello Step 1 (Figura 2): l'obesità amplifica drasticamente i costi sanitari specificamente nei fumatori, mentre per i non fumatori il BMI ha un effetto marginale quasi trascurabile sulla spesa a parità di età e figli.

Di conseguenza anche i coefficienti principali di **bmi** e **smoker_yes** cambiano interpretazione: rappresentano il valore stimato quando l'altra variabile coinvolta nell'interazione è pari a zero, non più un effetto medio costante. In particolare **smoker_yes** ora rappresenta l'effetto di essere fumatori quando **bmi**=0, un valore fuori dal range osservato (da 15.96 a 53.13) e privo di senso diretto. L'effetto complessivo del fumo, calcolato al BMI medio del campione ($\overline{\text{bmi}} = 30.66$), è $\hat{\beta}_4 + \hat{\beta}_5 \times 30.66 = -20\,195.20 + 1\,433.78 \times 30.66 \approx +23\,769$, coerente con la stima +\$23\,810 del modello senza interazione.

Tabella 10: Variance Inflation Factor, modello con interazione

Regressore	VIF
age	1.015
bmi	1.297
children	1.002
smoker_yes	25.14
smoker_yes $\times$ bmi	25.44

Il VIF evidenzia una collinearità elevata tra **smoker_yes** e il termine di interazione (VIF ≈ 25), conseguenza meccanica dell'uso di **bmi** non centrata: nel sottogruppo dei fumatori, **smoker_yes** $\times$ **bmi** è quasi proporzionale a **bmi** stessa. Questo non compromette la validità del modello (i coefficienti restano stimati correttamente e il termine di interazione resta altamente significativo), ma riduce la precisione con cui si può scomporre l'effetto tra i due termini correlati; centrando **bmi** sulla propria media si ridurrebbe il VIF senza alterare fit, R^2 o significatività, a scapito della diretta interpretabilità dei coefficienti principali in corrispondenza di **bmi**=0.

Tabella 11: Confronto dei test di eteroschedasticità: senza vs. con interazione

Test	LM senza interazione	p -value	LM con interazione	p -value
Breusch-Pagan	116.98	2.36×10^{-24}	7.07	0.215
White	128.25	4.65×10^{-21}	18.86	0.276

Entrambi i test non rigettano più H_0 di omoschedasticità a $\alpha = 0.05$: la statistica LM di Breusch-Pagan si riduce del 94.0% (da 116.98 a 7.07) e quella di White dell'85.3% (da 128.25 a 18.86). L'inserimento del termine di interazione **risolve l'eteroschedasticità** rilevata nella Sezione 4.2, confermando l'ipotesi formulata a partire dal pattern osservato nei dati.




Figura 8: Confronto Residui vs Fitted: modello senza interazione (sinistra) e con interazione $\text{smoker_yes} \times \text{bmi}$ (destra), colorati per smoker .

Il pannello destro mostra come, per i non fumatori, i residui si concentrino ora quasi perfettamente attorno allo zero per bassi valori stimati (l'effetto di bmi , non più significativo per questo gruppo, non introduce più variabilità residua sistematica); per i fumatori la dispersione resta presente ma non mostra più il pattern parabolico osservato in precedenza.




Figura 9: Istogramma dei residui con densità normale sovrapposta: modello senza interazione (sinistra) e con interazione (destra).

Va tuttavia notato un aspetto controintuitivo: skewness e curtosi dei residui peggiorano nel modello con interazione (skewness $1.22 \rightarrow 2.51$, curtosi $5.65 \rightarrow 10.25$), nonostante il netto miglioramento nei test BP e White. Questo non è contraddittorio: Breusch-Pagan e White verificano l'eteroschedasticità condizionata, cioè se la varianza dei residui dipende sistematicamente dai regressori tramite una regressione ausiliaria dei residui al quadrato; skewness e curtosi descrivono invece la forma non condizionata della distribuzione dei residui. Il modello con interazione si adatta così bene alla maggioranza delle osservazioni, in particolare ai non fumatori, i cui residui si concentrano quasi a zero (Figura 8), che le poche osservazioni anomale, verosimilmente pazienti con condizioni di salute non osservate nel dataset, risultano relativamente più estreme, aumentando la curtosi pur in assenza di una relazione sistematica varianza-regressori.

4.5 Rimedio 3: Modello Lineare Robusto (RLM)

Il Modello Lineare Robusto (RLM) è stato applicato anche al modello originale (senza interazione), come ulteriore strumento diagnostico indipendente dalla specificazione adottata, per verificare quanto le osservazioni anomale (outlier) influenzino le stime OLS: a differenza dei minimi quadrati ordinari, l'RLM attribuisce un peso $w_i < 1$ alle osservazioni con residuo elevato, riducendone l'impatto sulla stima dei coefficienti.

Tabella 12: Confronto coefficienti: OLS vs. RLM

Regressore	OLS	RLM
costante	-12 098.82	-5 476.02
age	257.77	265.74
bmi	321.87	56.64
children	472.98	442.21
smoker__yes	23 810.40	30 684.53

L'RLM assegna un peso molto basso (< 0.10) a circa 200 osservazioni anomale, perlopiù soggetti con **charges** molto elevate a parità di età/BMI (verosimilmente per fattori di rischio non osservati nel dataset). Poiché nel fit OLS tali outlier erano correlati con BMI elevato, l'OLS ne "gonfiava" artificialmente il coefficiente; una volta ridotto il loro peso, l'effetto di **bmi** si ridimensiona (da 322 a 57) mentre quello di **smoker_yes** aumenta (da 23 810 a 30 685), risultato coerente con l'ipotesi di una interazione **smoker** $\times$ **bmi** non modellata esplicitamente.




Figura 10: Distribuzione dei pesi assegnati dal Modello Lineare Robusto.

4.6 Sintesi

L'eteroschedasticità rilevata nel modello lin-lin originale (Sezione 4.2) trova una spiegazione strutturale nell'interazione tra **smoker** e **bmi**: includendo il termine **smoker_yes** $\times$ **bmi** nel modello, i test di Breusch-Pagan e White non rigettano più l'ipotesi di omoschedasticità, e l' R^2 sale da 0.750 a 0.839. La sola trasformazione logaritmica (Rimedio 1) non era invece sufficiente a risolvere il problema, confermando che la causa non era di scala ma di specificazione funzionale mancante. Il Modello Lineare Robusto (Rimedio 3), applicato al modello originale, resta un utile complemento diagnostico per individuare le osservazioni più influenti, indipendentemente dalla specificazione adottata.

5 Modelli Predittivi: Regularizzazione

5.1 Impostazione

A differenza degli Step precedenti, in questa sezione si utilizzano **tutti gli 8 regressori** codificati, lasciando che siano le tecniche di regularizzazione a operare la selezione/riduzione delle variabili in modo automatico. Il campione è stato suddiviso in training (80%, $n = 1069$) e test set (20%, $n = 268$); i regressori continui (`age`, `bmi`, `children`) sono stati standardizzati ($z = (x - \bar{x})/s$, scaler stimato solo sul training set per evitare *data leakage*), mentre le dummy restano in scala 0/1.

Le tre famiglie di modelli risolvono:

$$\text{Ridge: } \hat{\beta}_{\text{Ridge}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k \beta_j^2 \right\} \quad (12)$$

$$\text{LASSO: } \hat{\beta}_{\text{LASSO}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k |\beta_j| \right\} \quad (13)$$

$$\text{Elastic Net: } \hat{\beta}_{\text{EN}} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \left[\alpha \sum_{j=1}^k |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^k \beta_j^2 \right] \right\} \quad (14)$$

dove $\lambda \geq 0$ è il parametro di regularizzazione (in `scikit-learn`: `alpha`) e $\alpha \in [0, 1]$ (in `scikit-learn`: `l1_ratio`) pesa il contributo relativo delle penalità L1/L2 (testati $\alpha = 0.1$, a prevalenza Ridge, e $\alpha = 0.9$, a prevalenza LASSO).

È stata definita una griglia logaritmica decrescente di 100 valori, $\lambda \in \{10^4, \dots, 10^{-4}\}$, e per ciascun valore è stata eseguita una **10-fold cross-validation** sul training set (`sklearn.model_selection.KFold`, `cross_val_score`) minimizzando l'MSE medio sui fold.

5.2 Trace plot dei coefficienti

La Figura 11 mostra i *trace plot*: per λ grande tutti i coefficienti sono schiacciati verso 0; al decrescere di λ (verso destra, asse $-\log_{10} \lambda$) "si accendono" in ordine di importanza, con `smoker_yes` dominante seguito da `age` e `bmi`. Nel pannello LASSO si osserva la differenza qualitativa attesa rispetto a Ridge/Elastic Net: le variabili deboli (`sex_male` e le dummy di `region`) restano **esattamente a zero** per un ampio intervallo di λ , mentre con la penalità L2 (Ridge) si avvicinano a zero senza mai annullarsi: è la nota differenza strutturale tra shrinkage sparso (L1) e shrinkage continuo (L2).




Figura 11: Trace plot dei coefficienti in funzione di $-\log_{10}(\lambda)$.

5.3 Cross-Validation: MSE vs. $-\log(\lambda)$

La Figura 12 mostra le curve di CV-MSE (media $\pm$ errore standard sui 10 fold) in funzione di $-\log_{10}(\lambda)$. Il parametro di regolarizzazione ottimale $\lambda_{\min}$ è individuato come il valore che minimizza il CV-MSE medio sui 10 fold, evidenziato nel grafico da una linea verticale: è questo l'unico criterio adottato per la scelta di λ .




Figura 12: 10-fold CV MSE in funzione di $-\log_{10}(\lambda)$, con $\lambda_{\min}$ evidenziato (linea rossa).

5.4 Confronto dei modelli

La Tabella 13 riassume $\lambda_{\min}$, MSE di cross-validazione, MSE e R^2 sul test set, e numero di regressori non nulli per ciascun modello, confrontati con la baseline OLS (senza regolarizzazione) sullo stesso split.

Tabella 13: Confronto dei modelli di regolarizzazione (test set, $n = 268$)

Modello	$\lambda_{\min}$	Test MSE	Test RMSE	Test R^2	Regr. non nulli
Ridge	0.628	35.59×10^6	5 966	0.8063	8/8
LASSO	79.25	36.73×10^6	6 060	0.8001	4/8
Elastic Net ($\alpha = 0.1$)	0.0008	35.62×10^6	5 968	0.8062	8/8
Elastic Net ($\alpha = 0.9$)	0.0072	35.62×10^6	5 968	0.8062	8/8
OLS (no reg.)	0	35.48×10^6	5 956	0.8069	8/8




Figura 13: Confronto del Test RMSE tra i modelli.

Selezione delle variabili: LASSO azzerava esattamente `sex_male`, `region_northwest`, `region_southeast`, `region_southwest`: le *stesse identiche* variabili escluse dalla Best Subset Selection nello Step 2 (Sezione 3.4). Questa convergenza tra un criterio classico (basato su significatività/BIC) e uno di regolarizzazione automatica (basato su penalità L1) costituisce una forte conferma incrociata della robustezza del modello a 4 regressori.

Confronto degli MSE: sorprendentemente l'OLS non regolarizzato ottiene il Test RMSE più basso, per un margine contenuto ($\approx \$10$ su $\approx \$6\,000$, non rilevante in pratica). Ciò è coerente con la diagnosi di multicollinearità della Sez. 3.6: la regolarizzazione offre il massimo vantaggio quando vi è overfitting da collinearità o alta dimensionalità (p grande rispetto a n); qui invece $n = 1069 \gg p = 8$ e i regressori sono quasi ortogonali ($VIF \approx 1$), per cui Ridge ed Elastic Net convergono a λ_{min} vicino a zero (confermato dal fatto che i λ_{min} di Elastic Net si assestano su valori $\ll 1$, non sul bordo della griglia). Il costo del LASSO (RMSE leggermente più alto) riflette il classico *trade-off* bias-varianza: la penalità L1 introduce una piccola distorsione (shrinkage) sui coefficienti sopravvissuti (es. `bmi`: $1927 \rightarrow 1772$) in cambio di sparsità e interpretabilità, non di un guadagno predittivo in questo specifico dataset.

6 Conclusioni

L'analisi ha permesso di caratterizzare in modo rigoroso i determinanti della spesa sanitaria nel dataset *Medical Cost Personal Datasets*:

1. **Analisi descrittiva:** `charges` presenta una distribuzione fortemente asimmetrica e bimodale, generata principalmente dalla dicotomia fumatore/non fumatore.
2. **Modello inferenziale:** il modello finale $\text{charges} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{smoker_yes}$, selezionato tramite Best Subset Selection (BIC), spiega il 75% della varianza ($R_{adj}^2 = 0.749$) con tutti i coefficienti altamente significativi e nessuna multicollinearità rilevante ($VIF \approx 1$, $k = 291.6$). L'effetto di `smoker` (+\$23 810) domina nettamente quelli di `age` (+\$258/anno), `bmi` (+\$322/punto) e `children` (+\$473/figlio). Le variabili `sex` e `region` non risultano determinanti significativi della spesa.
3. **Eteroschedasticità:** confermata formalmente nel modello base (Breusch-Pagan e White, $p < 0.001$) e non risolta dalla sola trasformazione logaritmica. L'inserimento del termine di interazione `smoker_yes × bmi` risolve invece il problema: i test BP e White non rigettano più l'omoschedasticità ($p = 0.215$ e $p = 0.276$) e l' R^2 sale da 0.750 a 0.839, con l'interazione altamente significativa ($t = 27.13$, $p < 0.001$). L'effetto di `bmi` risulta pressoché nullo per

i non fumatori (\$5.68/punto, $p = 0.820$) e imponente per i fumatori (\$1 439.45/punto), spiegando il pattern osservato nell'analisi esplorativa. Gli errori standard robusti HC3 e il Modello Lineare Robusto, applicati al modello base, restano strumenti diagnostici complementari utili in assenza dell'estensione con interazione.

4. **Modelli predittivi:** Ridge, LASSO ed Elastic Net non migliorano la capacità predittiva rispetto all'OLS (Test RMSE compreso tra $\approx$ \$5 956 e \$6 060 in tutti i casi), coerentemente con l'assenza di collinearità e la bassa dimensionalità del problema ($n \gg p$). Il LASSO conferma però in modo del tutto indipendente, tramite selezione automatica via penalità L1, la stessa riduzione a 4 variabili individuata dalla Best Subset Selection: una validazione incrociata robusta della specificazione finale.

Limiti e sviluppi futuri: nonostante il netto miglioramento ottenuto con il termine di interazione (Sezione 4.4), la distribuzione dei residui mostra ancora code pesanti (skewness e curtosi superiori al caso base), segno della presenza di alcune osservazioni anomale non spiegate dalle variabili disponibili, verosimilmente legate a condizioni di salute preesistenti non osservate nel dataset. Un ulteriore sviluppo naturale sarebbe l'esplorazione di termini non lineari in `age` o di ulteriori interazioni (ad esempio `age×smoker`), oltre alla centratura di `bmi` per migliorare l'interpretabilità dei coefficienti principali in presenza dell'interazione.