

DataMedical Cost Personal Datasets (`insurance.csv`)

Cristian Trofusha, Samuele Epiceno, Giuseppe Antonio Arcuri, Miriam Formaro

23 agosto 2026

Indice

1	Introduzione	2
1.1	Descrizione del dataset	2
1.2	Obiettivi dell'analisi	2
1.3	Risultati attesi	2
2	Descrizione del dataset e Analisi Preliminare	2
2.1	Statistiche descrittive	2
2.2	Codifica delle variabili categoriche	3
2.3	Distribuzione della variabile target	3
2.4	Matrice di correlazione	4
2.5	Matrice di dispersione	4
3	Modelli Inferenziali, Forme Funzionali e Multicollinearita'	5
3.1	Il modello di regressione lineare multipla	5
3.2	Modello completo	5
3.3	Confronto dei possibili modelli	6
3.4	Selezione del modello: eliminazione dei regressori non significativi e Best Subset Selection	7
3.5	Analisi del modello finale	7
3.6	Multicollinearita'	8
4	Eteroschedasticita' e Analisi dei Residui	8
4.1	Analisi grafica	8
4.2	Test di Breusch-Pagan e White	9
4.3	Rimedio 1: trasformazione logaritmica	10
4.4	Rimedio 2: errori standard robusti (HC)	11
4.5	Rimedio 3: Modello Lineare Robusto (RLM)	11
4.6	Sintesi Step 3	12
5	Modelli Predittivi: Regolarizzazione	12
5.1	Impostazione	12
5.2	Trace plot dei coefficienti	13
5.3	Cross-Validation: MSE vs. $-\log(\lambda)$	14
5.4	Confronto dei modelli	15
6	Conclusioni	16

1 Introduzione

1.1 Descrizione del dataset

Il dataset *Medical Cost Personal Datasets* raccoglie $n = 1338$ osservazioni relative a beneficiari di polizze assicurative sanitarie negli Stati Uniti. Per ciascun individuo sono disponibili 7 variabili:

- **charges** (variabile target, continua): spesa medica annua addebitata dall'assicurazione, in USD;
- **age** (continua): età dell'assicurato, 18–64 anni;
- **sex** (categorica): **male** / **female**;
- **bmi** (continua): indice di massa corporea (kg/m^2);
- **children** (discreta): numero di figli a carico coperti dalla polizza, 0–5;
- **smoker** (categorica): **yes** / **no**;
- **region** (categorica): area residenziale USA (**northeast**, **northwest**, **southeast**, **southwest**).

Dopo la rimozione di un'osservazione duplicata (identica su tutte le variabili), il dataset di lavoro consta di $n = 1337$ osservazioni, senza valori mancanti.

1.2 Obiettivi dell'analisi

L'analisi persegue tre obiettivi complementari:

1. **Descrittivo**: visualizzare la distribuzione di **charges** e le relazioni con i regressori disponibili;
2. **Inferenziale**: stimare un modello di regressione lineare che identifichi i regressori statisticamente significativi della spesa sanitaria, valutandone la forma funzionale ottimale, la significatività congiunta e individuale dei regressori, e gestire l'eventuale presenza di multicollinearità ed eteroschedasticità;
3. **Predittivo**: confrontare tecniche di regolarizzazione (Ridge, LASSO, Elastic Net) con l'OLS classico in termini di errore di previsione fuori campione, valutandone la capacità di selezione automatica delle variabili.

1.3 Risultati attesi

Sulla base della letteratura relativa a questo dataset e dell'evidenza grafica preliminare, ci si attende che lo stato di fumatore (**smoker**) sia il principale determinante della spesa, seguito da età e BMI, con un effetto marginale del numero di figli; le variabili **sex** e **region** sono attese come non (o debolmente) significative. Data la forte asimmetria di **charges**, si ipotizza inoltre la presenza di eteroschedasticità nei residui del modello in livelli.

2 Descrizione del dataset e Analisi Preliminare

2.1 Statistiche descrittive

La Tabella 1 riporta le statistiche descrittive delle variabili numeriche.

Tabella 1: Statistiche descrittive delle variabili numeriche ($n = 1337$)

Variabile	Media	Std	Min	Q1	Mediana	Max
age	39.22	14.04	18.00	27.00	39.00	64.00
bmi	30.66	6.10	15.96	26.29	30.40	53.13
children	1.10	1.21	0.00	0.00	1.00	5.00
charges	13 279.12	12 110.36	1 121.87	4 746.34	9 386.16	63 770.43

Le variabili categoriche mostrano le seguenti frequenze: **sex** sostanzialmente bilanciato (50.5% *male*, 49.5% *female*); **smoker** fortemente sbilanciato (79.5% *no*, 20.5% *yes*, coerente con la prevalenza reale del fumo); **region** pressochè equidistribuita (southeast 27.2%, le altre tre $\approx 24\%$ ciascuna).

2.2 Codifica delle variabili categoriche

Le variabili categoriche sono state trasformate in variabili dummy (0/1) mediante *one-hot encoding*, escludendo la prima categoria in ordine alfabetico per ciascuna variabile (**drop_first=True**) al fine di evitare la *dummy variable trap*, ossia la collinearità perfetta che si avrebbe includendo tutte le categorie insieme all'intercetta: Le categorie di riferimento (baseline, corrispondenti a coefficiente nullo per costruzione) sono: **sex=female**, **smoker=no**, **region=northeast**. Si ottengono così 8 regressori: **age**, **bmi**, **children**, **sex_male**, **smoker_yes**, **region_northwest**, **region_southeast**, **region_southwest**.

2.3 Distribuzione della variabile target

La Figura 1 mostra istogramma e densità di **charges** in livelli e in logaritmo. La distribuzione in livelli è fortemente asimmetrica: skewness = 1.52, curtosis = 1.60 (rispetto a 0 della normale), con media (\$13 279) nettamente superiore alla mediana (\$9 386). La forma è inoltre chiaramente **bimodale**, con un secondo addensamento intorno a \$35 000–45 000. La trasformazione logaritmica riduce l'asimmetria ma non elimina del tutto la bimodalità residua.




Figura 1: Istogramma e densità di **charges** (sinistra) e di $\log(\text{charges})$ (destra).

La Figura 2 chiarisce l'origine della bimodalità: lo stato di fumatore separa nettamente due sotto-popolazioni con spesa media molto diversa (mediana $\approx \$34\,500$ per i fumatori contro $\approx \$7\,300$ per i non fumatori), e all'interno di ciascun gruppo la spesa cresce con età e BMI.




Figura 2: **charges** per stato di fumatore e relazione con **age**/**bmi** colorata per **smoker**.

2.4 Matrice di correlazione

La Figura 3 riporta la matrice di correlazione di Pearson tra tutte le variabili (dopo l'encoding). La correlazione con **charges** più forte è quella con **smoker_yes** ($\rho = 0.787$), seguita da **age** ($\rho = 0.298$) e **bmi** ($\rho = 0.198$); le altre variabili mostrano correlazioni deboli ($|\rho| < 0.08$). Le correlazioni tra i regressori sono contenute (il valore assoluto massimo, 0.35, si osserva tra le dummy di regione per costruzione), suggerendo a l'assenza di multicollinearità grave, ipotesi verificata formalmente nella Sezione 3.6.




Figura 3: Matrice di correlazione.

2.5 Matrice di dispersione

La Figura 4 mostra la scatterplot matrix delle variabili numeriche con rette di regressione costruite tramite OLS. La relazione **age**–**charges** appare quasi lineare "a strati" (dovuta ai sottogruppi **smoker**); **bmi**–**charges** è positiva ma più rumorosa; **children**–**charges** è pressochè piatta.




Figura 4: Scatterplot matrix delle variabili numeriche con rette di regressione.

3 Modelli Inferenziali, Forme Funzionali e Multicollinearita'

3.1 Il modello di regressione lineare multipla

Il modello di partenza (forma lin-lin, tutte le variabili in livelli) è:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{sex_male}_i + \beta_5 \text{smoker_yes}_i + \sum_r \gamma_r \text{region}_{r,i} + u_i \quad (1)$$

stimato con il metodo dei minimi quadrati ordinari, sotto le ipotesi di Gauss-Markov ($\mathbb{E}[u_i|X_i] = 0$, $\text{Var}(u_i|X_i) = \sigma^2$, $\text{Cov}(u_i, u_j|X) = 0$ per $i \neq j$).

3.2 Modello completo

La Tabella 2 riporta l'output del modello (1) con tutti gli 8 regressori.

Tabella 2: Modello OLS completo (lin-lin): $R^2 = 0.751$, $R_{adj}^2 = 0.749$, $F(8, 1328) = 500.0$ ($p \approx 0$)

Regressore	Coeff.	Std. Err.	t	p -value	Sign.
costante	-11 940.0	988.23	-12.08	< 0.001	***
age	256.76	11.91	21.56	< 0.001	***
bmi	339.25	28.61	11.86	< 0.001	***
children	474.82	137.90	3.44	0.001	***
sex_male	-129.48	333.20	-0.39	0.698	n.s.
smoker_yes	23 850.0	413.35	57.69	< 0.001	***
region_northwest	-349.23	476.82	-0.73	0.464	n.s.
region_southeast	-1 035.27	478.87	-2.16	0.031	*
region_southwest	-960.08	478.11	-2.01	0.045	*

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; n.s. non significativo

I residui del modello completo mostrano forte non-normalità (skewness = 1.21, curtosi = 5.65), un primo segnale d'allarme che verrà approfondito nella Sezione 4.

3.3 Confronto dei possibili modelli

Sono state confrontate quattro modelli: lin-lin, log-log, log-lin e lin-log:

$$\text{lin-lin: } y = \beta_0 + \beta' \mathbf{x} + u \quad (2)$$

$$\text{log-log: } \ln(y) = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (3)$$

$$\text{log-lin: } \ln(y) = \beta_0 + \beta' \mathbf{x} + u \quad (4)$$

$$\text{lin-log: } y = \beta_0 + \beta_1 \ln(\text{age}) + \beta_2 \ln(\text{bmi}) + \gamma' \mathbf{z} + u \quad (5)$$

dove $\mathbf{z}$ raccoglie **children** e le dummy (che restano sempre in livelli, poichè il logaritmo non è definito per **children**=0 e privo di senso per variabili binarie).

Tabella 3: Confronto delle forme funzionali

Forma	Y	R^2	R_{adj}^2	AIC	Skew resid.	Kurt resid.
lin-lin	charges	0.751	0.749	27 094.2	1.21	5.65
log-log	$\ln(\text{charges})$	0.769	0.767	1 627.4	1.85	7.67
log-lin	$\ln(\text{charges})$	0.768	0.766	1 633.2	1.68	7.32
lin-log	charges	0.744	0.743	27 127.8	1.18	5.45

R^2 , AIC e BIC non sono direttamente confrontabili tra modelli con variabile dipendente su scala diversa (charges vs. $\ln(\text{charges})$), poichè la devianza totale da spiegare cambia; il confronto è valido solo *entro* lo stesso gruppo (lin-lin vs. lin-log; log-log vs. log-lin). Un confronto in scala originaria (\$), ottenuto ritrasformando le previsioni dei modelli in $\ln(y)$ con lo *smearing estimator* di Duan (1983)

$$\hat{y}_i = \exp(\hat{u}_i^{\ln}) \cdot \underbrace{\frac{1}{n} \sum_{j=1}^n \exp(\hat{e}_j)}_{\text{fattore di smearing}} \quad (6)$$

(che corregge la distorsione da disuguaglianza di Jensen, $\mathbb{E}[\exp(u)] \neq \exp(\mathbb{E}[u])$), favorisce sistematicamente i modelli in livelli poichè l'OLS lin-lin minimizza esattamente la somma dei quadrati in \$ per costruzione: non è quindi un criterio adeguato per la scelta della forma funzionale. Il criterio adottato è invece: (i) confronto entro lo stesso scale di Y (R_{adj}^2 /AIC/BIC),

che premia il lin-lin nel gruppo charges e il log-log (di poco) nel gruppo $\ln(\text{charges})$; (ii) skewness/curtosi dei residui, che misurano quanto la trasformazione mitiga l'asimmetria vista in Sez. 2 – criterio in cui il lin-lin risulta il migliore in assoluto. La forma **lin-lin** viene quindi selezionata per lo Step 2, essendo la piu' parsimoniosa, con il miglior fit nel proprio gruppo e i residui meno asimmetrici; l'eventuale rimedio della trasformazione logaritmica viene riesaminato formalmente alla luce dei test di eteroschedasticita' (Sezione 4), coerentemente con l'evidenza che nessuna delle due trasformazioni elimina la bimodalita' residua legata a **smoker**.

3.4 Selezione del modello: eliminazione dei regressori non significativi e Best Subset Selection

Sono state applicate due procedure indipendenti sulla forma lin-lin:

1. **Backward elimination**: rimozione iterativa del regressore con p -value piu' alto finche' tutti i rimanenti risultano significativi a $\alpha = 0.05$. Sequenza di rimozione: **sex_male** ($p = 0.698$) $\rightarrow$ **region_northwest** ($p = 0.465$) $\rightarrow$ **region_southwest** ($p = 0.058$) $\rightarrow$ **region_southeast** ($p = 0.136$).
2. **Best Subset Selection**: ricerca esaustiva su tutte le $2^8 - 1 = 255$ combinazioni non vuote di regressori, minimizzando il criterio BIC

$$\text{BIC} = n \ln(\text{SSE}/n) + k \ln(n) \quad (7)$$

che penalizza la complessita' piu' severamente dell'AIC ed e' quindi preferibile quando l'obiettivo e' un modello parsimonioso.

Entrambe le procedure convergono **sullo stesso modello finale**:

$$\text{charges}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{bmi}_i + \beta_3 \text{children}_i + \beta_4 \text{smoker_yes}_i + u_i \quad (8)$$

(BIC= 27 118.7 contro BIC= 27 141.0 del modello completo; il modello a 6 regressori scelto dal criterio AIC/ R^2_{adj} differisce di appena 0.0007 in R^2_{adj} e viene scartato in favore della maggiore parsimonia).

3.5 Analisi del modello finale

La Tabella 4 riporta l'output completo del modello (8).

Tabella 4: Modello finale (lin-lin, 4 regressori)

Regressore	Coeff.	Std.Err.	t	p -value	IC 95%
costante	-12 098.82	942.63	-12.84	< 0.001	[-13 948, -10 250]
age	257.77	11.91	21.64	< 0.001	[234.4, 281.1]
bmi	321.87	27.39	11.75	< 0.001	[268.1, 375.6]
children	472.98	137.88	3.43	0.001	[202.5, 743.5]
smoker_yes	23 810.40	411.41	57.87	< 0.001	[23 003, 24 617]

Bonta' di adattamento: $R^2 = 0.750$, $R^2_{adj} = 0.749$ – il modello spiega il 75% della varianza di **charges**, valore praticamente identico a quello del modello completo (0.751), a conferma che le variabili escluse non aggiungono potere esplicativo.

Test F globale:

$$F = \frac{(\text{SSR}_{\text{ristretto}} - \text{SSR}_{\text{completo}})/q}{\text{SSR}_{\text{completo}}/(n - k - 1)} \sim F_{q, n-k-1} \quad \text{sotto } H_0 : \beta_1 = \dots = \beta_k = 0 \quad (9)$$

$F(4, 1332) = 996.5$, $p \approx 0$: si rigetta nettamente H_0 , il modello nel suo complesso e' altamente significativo.

Test t sui singoli coefficienti ($H_0 : \beta_j = 0$ vs. $H_1 : \beta_j \neq 0$, statistica $t = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$): tutti e 4 i regressori sono significativi a livello 0.1%. Interpretazione economica: a parita' delle altre covariate, un anno di eta' in piu' e' associato a +\$258 di spesa attesa; un punto di BMI in piu' a +\$322; un figlio in piu' a +\$473; essere fumatori a +\$23 810 – effetto di gran lunga dominante, coerente con la correlazione $\rho = 0.787$ osservata in Sez. 2.

3.6 Multicollinearita'

Il **Variance Inflation Factor** per il regressore j e' definito come

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (10)$$

dove R_j^2 e' il coefficiente di determinazione della regressione di x_j su tutti gli altri regressori. La Tabella 5 riporta i VIF del modello finale.

Tabella 5: Variance Inflation Factor – modello finale

Regressore	VIF
age	1.014
bmi	1.012
children	1.002
smoker_yes	1.001

Tutti i VIF sono prossimi a 1 (soglia di allarme convenzionale: $\text{VIF} \geq 10$; attenzione per $5 \leq \text{VIF} < 10$): nessuna multicollinearita' rilevante tra i regressori.

Come indicatore complementare e' stato calcolato il **Condition Number** k secondo il metodo di Belsley–Kuh–Welsch: le colonne della matrice disegno X (inclusa la costante) sono scalate a norma unitaria (senza centrare, per non mascherare collinearita' che coinvolge l'intercetta), quindi

$$k = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \frac{\sigma_{\max}(X_{\text{scaled}})}{\sigma_{\min}(X_{\text{scaled}})} \quad (11)$$

dove $\sigma_{\max}, \sigma_{\min}$ sono il massimo e il minimo valore singolare. Si ottiene $k = 14.16$ (soglie di riferimento: $k < 10$ nessun problema, $10 \leq k < 30$ moderato, $k \geq 30$ severo), un valore di multicollinearita' *moderata* secondo la regola pratica, ma coerente con i $\text{VIF} \approx 1$: l'inflazione residua e' dovuta principalmente alla diversa scala delle variabili (age/bmi in decine vs. dummy 0/1) piu' che a vera collinearita'. Il condition number "grezzo" restituito da `statsmodels` sulla matrice non scalata (291.6) e' fuorviante per lo stesso motivo ed e' riportato solo come controllo incrociato. **Conclusione**: nessun problema di multicollinearita' nel modello finale.

4 Eteroschedasticita' e Analisi dei Residui

4.1 Analisi grafica

La Figura 5 mostra i residui del modello finale (8) contro i valori stimati, colorati per stato di fumatore. Si osservano due nubi nettamente separate, ciascuna con un pattern "a imbuto"/curvo – sintomo combinato di eteroschedasticita' e di non linearita' residua (verosimile interazione `smoker` $\times$ `bmi` non inclusa nel modello additivo). L'istogramma dei residui mostra una bimodalita' residua rispetto alla densita' normale sovrapposta.




Figura 5: Residui vs. Fitted values (colorati per **smoker**) e istogramma dei residui con densita' normale teorica sovrapposta.

Il Q-Q plot (Figura 6) conferma code pesanti a destra e scostamento sistematico dalla normalita'.




Figura 6: Q-Q plot dei residui studentizzati del modello finale.

4.2 Test di Breusch-Pagan e White

Il test di **Breusch-Pagan** verifica $H_0 : \text{Var}(u_i|X_i) = \sigma^2$ (omoschedasticita') contro H_1 : la varianza dipende linearmente dai regressori, tramite la regressione ausiliaria $\hat{u}_i^2 = \delta_0 + \delta_1 x_{1i} + \dots + \delta_k x_{ki} + v_i$ e la statistica $\text{LM} = nR_{aux}^2 \sim \chi_k^2$. Il test di **White** generalizza includendo nella regressione ausiliaria anche quadrati e prodotti incrociati dei regressori, risultando robusto a forme di eteroschedasticita' non lineari.

Tabella 6: Test di eteroschedasticita' sul modello finale (lin-lin)

Test	Statistica	p -value	Statistica F	p -value (F)
Breusch-Pagan	LM= 116.98	2.36×10^{-24}	31.93	1.95×10^{-25}
White	LM= 128.25	4.65×10^{-21}	10.80	3.39×10^{-22}

Entrambi i test rigettano nettamente H_0 ($p < 0.001$): **eteroschedasticita' confermata**.

4.3 Rimedio 1: trasformazione logaritmica

Applicando $\ln(\text{charges})$ come variabile dipendente sugli stessi 4 regressori si ottiene $R^2 = 0.762$, $R^2_{adj} = 0.761$ (Tabella 7).

Tabella 7: Modello log-lin: $\ln(\text{charges}) = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{smoker_yes} + u$

Regressore	Coeff.	Std. Err.	t	p -value
costante	6.9850	0.070	100.17	< 0.001
age	0.0347	0.001	39.43	< 0.001
bmi	0.0106	0.002	5.24	< 0.001
children	0.1009	0.010	9.89	< 0.001
smoker_yes	1.5427	0.030	50.69	< 0.001

I coefficienti si interpretano come semi-elasticita': $\exp(\hat{\beta}_j) - 1$ e' la variazione percentuale attesa di **charges** per un incremento unitario di x_j . Ad esempio, essere fumatori e' associato a $(\exp(1.5427) - 1) \times 100 \approx 368\%$ di spesa in piu', a parita' di eta'/BMI/figli.

Ripetendo i test sui residui di questo modello (Tabella 8):

Tabella 8: Test di eteroschedasticita' sul modello log-lin

Test	Statistica	p -value	Statistica F	p -value (F)
Breusch-Pagan	LM= 81.23	9.56×10^{-17}	21.54	3.08×10^{-17}
White	LM= 140.86	1.41×10^{-23}	11.99	5.47×10^{-25}

L'eteroschedasticita' **persiste** (anzi il test di White peggiora leggermente). Il grafico Residuals vs-Fitted in scala logaritmica (Figura 7, pannello destro) mostra un pattern a "V" ancora piu' marcato che nel lin-lin: la trasformazione logaritmica da sola non risolve il problema, poiche' la causa non e' (solo) una relazione moltiplicativa media-varianza ma una interazione strutturale **smoker** $\times$ **bmi**/**age** assente da entrambe le specificazioni additive.




Figura 7: Confronto Residui vs. Fitted: modello lin-lin (sinistra) contro log-lin (destra).

4.4 Rimedio 2: errori standard robusti (HC)

In presenza di eteroschedasticita' lo stimatore OLS $\hat{\beta}$ resta non distorto e consistente (BLUE decade solo l'efficienza), ma la formula classica della varianza $\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1}$ non e' piu' valida. Si adotta lo stimatore *sandwich* Heteroskedasticity-Consistent (HC) di White:

$$\widehat{\text{Var}}_{HC}(\hat{\beta}) = (X'X)^{-1} \left(\sum_i \hat{u}_i^2 x_i x_i' \right) (X'X)^{-1} \quad (12)$$

con varianti HC0/HC1/HC3 che differiscono per il fattore di correzione dei gradi di liberta' (HC3 e' generalmente il piu' conservativo e raccomandato in campioni medio-piccoli).

Tabella 9: Confronto standard error: OLS classico vs. HC

Regressore	Coeff.	SE OLS	SE HC0	SE HC3	$\Delta\%$ HC3
costante	-12 098.82	942.63	986.19	991.94	+5.2%
age	257.77	11.91	11.82	11.88	-0.3%
bmi	321.87	27.39	29.89	30.08	+9.8%
children	472.98	137.88	130.51	131.27	-4.8%
smoker_yes	23 810.40	411.41	570.54	573.84	+39.5%

I coefficienti restano **identici**; cambiano solo gli standard error (e di conseguenza t , p -value, IC). Lo SE di **smoker_yes** si allarga del 39.5%, coerentemente con la maggiore dispersione dei residui nel sottogruppo fumatori osservata in Figura 5: la stima "classica" sottostimava l'incertezza su questo coefficiente. Tutti i regressori restano comunque altamente significativi anche con errori robusti HC3.

4.5 Rimedio 3: Modello Lineare Robusto (RLM)

Il Modello Lineare Robusto stima $\hat{\beta}$ minimizzando una funzione di perdita meno sensibile agli outlier rispetto alla somma dei quadrati. Con la norma di Huber:

$$\rho_{Huber}(u) = \begin{cases} \frac{1}{2}u^2 & |u| \leq c \\ c|u| - \frac{1}{2}c^2 & |u| > c \end{cases} \quad (13)$$

stimato tramite *Iteratively Reweighted Least Squares* (IRLS), che assegna un peso $w_i < 1$ alle osservazioni con residuo elevato.

Tabella 10: Confronto coefficienti: OLS vs. RLM (Huber-T)

Regressore	OLS	RLM
costante	-12 098.82	-5 476.02
age	257.77	265.74
bmi	321.87	56.64
children	472.98	442.21
smoker_yes	23 810.40	30 684.53

L'RLM assegna un peso molto basso (< 0.10) a circa 200 osservazioni anomale, perlopiu' soggetti con **charges** molto elevate a parita' di eta'/BMI (verosimilmente per fattori di rischio non osservati nel dataset). Poiche' nel fit OLS tali outlier erano correlati con BMI elevato, l'OLS ne "gonfiava" artificialmente il coefficiente; una volta ridotto il loro peso, l'effetto di **bmi** si ridimensiona (da 322 a 57) mentre quello di **smoker_yes** aumenta (da 23 810 a 30 685) – risultato coerente con l'ipotesi di una interazione **smoker** $\times$ **bmi** non modellata esplicitamente.




Figura 8: Distribuzione dei pesi assegnati dal Modello Lineare Robusto.

4.6 Sintesi Step 3

L'eteroschedasticita' e' confermata formalmente sia in lin-lin sia in log-lin: la trasformazione logaritmica da sola non basta, poiche' la causa e' strutturale (interazione mancante) piu' che di scala. Gli **errori standard HC3** rappresentano il rimedio minimale per un'inferenza valida senza cambiare la specificazione, mentre l'**RLM** rivela quanto gli outlier distorcano i coefficienti OLS di **bmi** e **smoker_yes** – utile complemento diagnostico, pur non risolvendo di per se' l'eteroschedasticita' (e' un rimedio per la non-robustezza agli outlier, non per la eteroschedasticita' in senso stretto).

5 Modelli Predittivi: Regularizzazione

5.1 Impostazione

A differenza degli Step precedenti, in questa sezione si utilizzano **tutti gli 8 regressori** codificati, lasciando che siano le tecniche di regularizzazione a operare la selezione/riduzione delle variabili in modo automatico. Il campione e' stato suddiviso in training (80%, $n = 1069$) e test set (20%, $n = 268$); i regressori continui (**age**, **bmi**, **children**) sono stati standardizzati ($z = (x - \bar{x})/s$,

scaler stimato solo sul training set per evitare *data leakage*), mentre le dummy restano in scala 0/1.

Le tre famiglie di modelli risolvono:

$$\text{Ridge: } \hat{\beta}_{Ridge} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k \beta_j^2 \right\} \quad (14)$$

$$\text{LASSO: } \hat{\beta}_{LASSO} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \sum_{j=1}^k |\beta_j| \right\} \quad (15)$$

$$\text{Elastic Net: } \hat{\beta}_{EN} = \arg \min_{\beta} \left\{ \text{SSE} + \lambda \left[\alpha \sum_{j=1}^k |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^k \beta_j^2 \right] \right\} \quad (16)$$

dove $\lambda \geq 0$ e' il parametro di regolarizzazione (in `scikit-learn`: `alpha`) e $\alpha \in [0, 1]$ (in `scikit-learn`: `l1_ratio`) pesa il contributo relativo delle penalita' L1/L2 (testati $\alpha = 0.1$, a prevalenza Ridge, e $\alpha = 0.9$, a prevalenza LASSO).

E' stata definita una griglia logaritmica decrescente di 100 valori, $\lambda \in \{10^4, \dots, 10^{-4}\}$, e per ciascun valore e' stata eseguita una **10-fold cross-validation** sul training set (`sklearn.model_selection.KFold`, `cross_val_score`) minimizzando l'MSE medio sui fold.

5.2 Trace plot dei coefficienti

La Figura 9 mostra i *trace plot*: per λ grande tutti i coefficienti sono schiacciati verso 0; al decrescere di λ (verso destra, asse $-\log_{10} \lambda$) "si accendono" in ordine di importanza, con **smoker_yes** dominante seguito da **age** e **bmi**. Nel pannello LASSO si osserva la differenza qualitativa attesa rispetto a Ridge/Elastic Net: le variabili deboli (**sex_male** e le dummy di **region**) restano **esattamente a zero** per un ampio intervallo di λ , mentre con la penalita' L2 (Ridge) si avvicinano a zero senza mai annullarsi – e' la nota differenza strutturale tra shrinkage sparso (L1) e shrinkage continuo (L2).




Figura 9: Trace plot dei coefficienti in funzione di $-\log_{10}(\lambda)$.

5.3 Cross-Validation: MSE vs. $-\log(\lambda)$

La Figura 10 mostra le curve di CV-MSE (media $\pm$ errore standard sui 10 fold) in funzione di $-\log_{10}(\lambda)$, con linee verticali per λ_{min} (minimo CV-MSE) e λ_{1se} (regola dell'errore standard: il λ piu' grande - modello piu' parsimonioso - il cui CV-MSE resta entro 1 SE dal minimo, convenzione standard `glmnet`).




Figura 10: 10-fold CV MSE in funzione di $-\log_{10}(\lambda)$, con λ_{min} (rosso) e λ_{1se} (verde).

5.4 Confronto dei modelli

La Tabella 11 riassume λ_{min} , MSE di cross-validation, MSE e R^2 sul test set, e numero di regressori non nulli per ciascun modello, confrontati con la baseline OLS (senza regolarizzazione) sullo stesso split.

Tabella 11: Confronto dei modelli di regolarizzazione (test set, $n = 268$)

Modello	λ_{min}	Test MSE	Test RMSE	Test R^2	Regr. non nulli
Ridge	0.628	35.59×10^6	5 966	0.8063	8/8
LASSO	79.25	36.73×10^6	6 060	0.8001	4/8
Elastic Net ($\alpha = 0.1$)	0.0008	35.62×10^6	5 968	0.8062	8/8
Elastic Net ($\alpha = 0.9$)	0.0072	35.62×10^6	5 968	0.8062	8/8
OLS (no reg.)	0	35.48×10^6	5 956	0.8069	8/8




Figura 11: Confronto del Test RMSE tra i modelli.

Selezione delle variabili: LASSO azzerava esattamente `sex_male`, `region_northwest`, `region_southeast`, `region_southwest` – le *stesse identiche* variabili escluse dalla backward elimination e dalla Best Subset Selection nello Step 2 (Sezione 3.4). Questa convergenza tra un criterio classico (basato su significatività/BIC) e uno di regolarizzazione automatica (basato su penalità L1) costituisce una forte conferma incrociata della robustezza del modello a 4 regressori.

Confronto degli MSE: sorprendentemente l'OLS non regolarizzato ottiene il Test RMSE più basso, per un margine contenuto ($\approx \$10$ su $\approx \$6000$, non rilevante in pratica). Ciò è coerente con la diagnosi di multicollinearità della Sez. 3.6: la regolarizzazione offre il massimo vantaggio quando vi è overfitting da collinearità o alta dimensionalità (p grande rispetto a n); qui invece $n = 1069 \gg p = 8$ e i regressori sono quasi ortogonali ($VIF \approx 1$), per cui Ridge ed Elastic Net convergono a λ_{min} vicino a zero (confermato dal fatto che i λ_{min} di Elastic Net si assestano su valori $\ll 1$, non sul bordo della griglia). Il costo del LASSO (RMSE leggermente più alto) riflette il classico *trade-off* bias-varianza: la penalità L1 introduce una piccola distorsione (shrinkage) sui coefficienti sopravvissuti (es. `bmi`: $1927 \rightarrow 1772$) in cambio di sparsità e interpretabilità, non di un guadagno predittivo in questo specifico dataset.

6 Conclusioni

L'analisi ha permesso di caratterizzare in modo rigoroso i determinanti della spesa sanitaria nel dataset *Medical Cost Personal Datasets*:

1. **Analisi descrittiva:** `charges` presenta una distribuzione fortemente asimmetrica e bimodale, generata principalmente dalla dicotomia fumatore/non fumatore.
2. **Modello inferenziale:** il modello finale $\text{charges} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{bmi} + \beta_3 \text{children} + \beta_4 \text{smoker_yes}$, selezionato concordemente da backward elimination e Best Subset Selection (BIC), spiega il 75% della varianza ($R_{adj}^2 = 0.749$) con tutti i coefficienti altamente significativi e nessuna multicollinearità rilevante ($VIF \approx 1$, $k = 14.16$). L'effetto di `smoker` (+\$23810) domina nettamente quelli di `age` (+\$258/anno), `bmi` (+\$322/punto) e `children` (+\$473/figlio). Le variabili `sex` e `region` non risultano determinanti significativi della spesa.
3. **Eteroschedasticità:** confermata formalmente (Breusch-Pagan e White, $p < 0.001$) e non risolta dalla sola trasformazione logaritmica, a causa di una probabile interazione strutturale `smoker`×`bmi` non catturata dal modello additivo. Gli errori standard robusti HC3 correggono correttamente l'inferenza (in particolare ampliando lo SE di `smoker_yes`

del 39.5%), mentre il Modello Lineare Robusto rivela che gli outlier distorcono sensibilmente le stime OLS di `bmi` e `smoker_yes`.

4. **Modelli predittivi:** Ridge, LASSO ed Elastic Net non migliorano la capacità predittiva rispetto all'OLS (Test RMSE $\approx$ \$5 956–6 060 in tutti i casi), coerentemente con l'assenza di collinearità e la bassa dimensionalità del problema ($n \gg p$). Il LASSO conferma però in modo del tutto indipendente, tramite selezione automatica via penalità L1, la stessa riduzione a 4 variabili individuata dai metodi classici – una validazione incrociata robusta della specificazione finale.

Limiti e sviluppi futuri: i pattern residui osservati (Sez. 4) suggeriscono che un'estensione naturale del modello sarebbe l'inclusione di un termine di interazione `smoker` $\times$ `bmi` (e eventualmente termini non lineari in `age`), che potrebbe contestualmente migliorare il fit e mitigare l'eteroschedasticità residua, a scapito di una minore parsimonia interpretativa.